



Universitatea Politehnica Bucureşti
Facultatea de Automatică și Calculatoare
Departamentul de Automatică și Ingineria Sistemelor

LUCRARE DE LICENȚĂ

Identificare neliniară pe bază de modele NARMAX

Absolvent
Andreea-Cristina VOINEA

Coordonator
Prof.univ.dr.ing. Dan ȘTEFĂNOIU

Bucureşti, iulie 2022

Înainte de toate, doresc să aduc mulțumiri domnului profesor coordonator, prof.univ.dr.ing. Dan Ștefănoiu, pentru sprijinul constant acordat pe toată durata elaborării lucrării, precum și pentru modul profesionist de predare și evaluare a noțiunilor de Prelucrarea Semnalelor și Identificarea Sistemelor, care m-a ajutat să capăt încredere în forțele proprii și să evoluez în încercarea de a deveni un adevărat inginer de sistem.

De asemenea, țin să-i mulțumesc doamnei conf.dr.ing Janetta Culiță pentru ajutorul substanțial primit în cadrul etapei de implementare a proiectului.

Andreea-Cristina Voinea

CUPRINS

1. Introducere.....	5
2. Modele de identificare SISO-NARMAX.....	6
3. Metoda de identificare a modelelor SISO-NARMAX.....	8
3.1. Noțiuni generale privind metodele de identificare.....	8
3.2. Descrierea Metodei Celor Mai Mici Pătrate Multi-Pas.....	10
3.3. Tehnica Ortogonalizării Regresorilor.....	11
4. Determinarea optimal-metaeuristică a indicilor structurali.....	12
4.1. Motivația necesității utilizării unei metaeuristici.....	12
4.2. Metaeuristica Algoritmilor Genetici.....	13
4.3. Formularea problemei de optimizare.....	14
5. Studiu de caz: identificarea MISO-NARMAX a instalației ASTANK2.....	15
5.1. Descrierea instalației ASTANK2.....	15
5.2. Identificarea instalației ASTANK2.....	18
5.2.1. ASTANK2 ca proces de tip MISO.....	18
5.2.2. Implementarea metodei de identificare.....	20
5.3. Adaptarea Algoritmilor Genetici.....	21
5.3.1. Definirea funcției cost specifice.....	21
5.3.2. Calculul funcției <i>fitness</i> prin simularea modelului NARMAX.....	22
5.3.3. Funcția GA din MATLAB.....	25
6. Rezultate de simulare.....	28
6.1. Seturi de date achiziționate.....	28
6.2. Modelele optimale obținute.....	30
6.3. Performanțele modelelor optimale.....	32
7. Concluzii și dezvoltări posibile ulterioare.....	47
 Lista contribuților personale.....	49
 Bibliografie.....	50

Listă de figuri

2.1. Schema de principiu a modelului SISO-NARMAX.....	8
4.1. Adaptarea AG la problema de optimizare.....	15
5.1. Schema instalației ASTANK2.....	16
5.2. Schema conceptuală simplificată a instalației ASTANK2.....	17
5.3. Schema de simulare a modelului multi-MISO-NARMAX, asociat instalației ASTANK2.....	18
5.4. Structura cromozomului γ pentru modelul NARMAX.....	22
5.5. Structura logică a unui AG.....	26
6.1. Semnale de intrare utilizate pentru achiziția seturilor de date, pentru ambele canale de la instalația ASTANK2.....	29
6.2. Semnale de ieșire furnizate de cele două canale ale instalației ASTANK2, după stimularea cu intrările de identificare.....	29
6.3. Semnale de ieșire furnizate de cele două canale ale instalației ASTANK2, după stimularea cu intrările de validare.....	30
6.4. Semnale de ieșire măsurate versus utile simulate pe canalul 1 de ieșire, orizontul de identificare.....	33
6.5. Zgomotul alb estimat în cadrul procedurii numerice aferente MCMMMP-MP, pe canalul 1 de ieșire, orizontul de identificare	33
6.6. Zgomotele colorate simulate versus estimate pe canalul 1 de ieșire, orizontul de identificare.....	33
6.7. Semnale de ieșire măsurate versus integral simulate pe canalul 1 de ieșire, orizontul de identificare.....	34
6.8. Erori de model pe canalul 1 de ieșire, orizontul de identificare.....	34
6.9. Semnale de ieșire măsurate versus utile simulate pe canalul 2 de ieșire, orizontul de identificare.....	35
6.10. Zgomotul alb estimat în cadrul procedurii numerice aferente MCMMMP-MP, pe canalul 2 de ieșire, orizontul de identificare.....	35
6.11. Zgomotele colorate simulate versus estimate pe canalul 2 de ieșire, orizontul de identificare.....	35
6.12. Semnale de ieșire măsurate versus integral simulate pe canalul 2 ieșire,orizontul de identificare.....	36
6.13. Erori de model pe canalul 2 de ieșire, orizontul de identificare.....	36
6.14. Semnale de ieșire măsurate versus utile simulate pe canalul 1 de ieșire, orizontul de validare.....	36
6.15. Zgomotele colorate simulate versus estimate pe canalul 1 de ieșire, orizontul de validare.....	36
6.16. Semnale de ieșire măsurate versus integral simulate pe canalul 1 de ieșire, orizontul de validare.....	37
6.17. Erori de model pe canalul 1 de ieșire, orizontul de validare.....	37
6.18. Semnale de ieșire măsurate versus utile simulate pe canalul 2 de ieșire, orizontul de validare.....	37
6.19. Zgomotele colorate simulate versus estimate pe canalul 2 de ieșire, orizontul de validare.....	37
6.20. Semnale de ieșire măsurate versus integral simulate pe canalul 2 de ieșire, orizontul de validare.....	38

6.21. Erori de model pe canalul 2 de ieșire, orizontul de validare.....	38
6.22. Semnalul de ieșire măsurat versus util simulat pe canalul 1 de ieșire, orizontul de identificare (scenariul MULTI-PAS).....	38
6.23. Zgomotul alb estimat în cadrul procedurii numerice aferente MCMMMP-MP, pe canalul 1 de ieșire, orizontul de identificare (scenariul MULTI-PAS).....	39
6.24. Zgomotul colorat simulat versus estimat pe canalul 1 de ieșire, orizontul de identificare (scenariul MULTI-PAS).....	39
6.25. Semnalul de ieșire măsurat versus integral simulat pe canalul 1 de ieșire, orizontul de identificare (scenariul MULTI-PAS).....	40
6.26. Eroarea de model pe canalul 1 de ieșire, orizontul de identificare (scenariul MULTI-PAS).....	40
6.27. Semnalul de ieșire măsurat versus util simulat pe canalul 2 de ieșire, orizontul de identificare (scenariul MULTI-PAS).....	41
6.28. Zgomotul alb estimat în cadrul procedurii numerice aferente MCMMMP-MP, pe canalul 2 de ieșire, orizontul de identificare (scenariul MULTI-PAS).....	41
6.29. Zgomotul colorat simulat versus estimat pe canalul 2 de ieșire, orizontul de identificare (scenariul MULTI-PAS).....	42
6.30. Semnalul de ieșire măsurat versus integral simulat pe canalul 2 de ieșire, orizontul de identificare (scenariul MULTI-PAS).....	42
6.31. Eroarea de model pe canalul 2 de ieșire, orizontul de identificare (scenariul MULTI-PAS).....	43
6.32. Semnalul de ieșire măsurat versus util simulat pe canalul 1 de ieșire, orizontul de validare (scenariul MULTI-PAS).....	43
6.33. Zgomotul colorat simulat versus estimat pe canalul 1 de ieșire, orizontul de validare (scenariul MULTI-PAS).....	44
6.34. Semnalul de ieșire măsurat versus integral simulat pe canalul 1 de ieșire, orizontul de validare.....	44
6.35. Eroarea de model pe canalul 1 de ieșire, orizontul de validare (scenariul MULTI-PAS).....	45
6.36. Semnalul de ieșire măsurat versus util simulat pe canalul 2 de ieșire, orizontul de validare (scenariul MULTI-PAS).....	45
6.37. Zgomotul colorat simulat versus estimat pe canalul 2 de ieșire, orizontul de validare (scenariul MULTI-PAS).....	46
6.38. Semnalul de ieșire măsurat versus integral simulat pe canalul 2 de ieșire, orizontul de validare (scenariul MULTI-PAS).....	46
6.39. Eroarea de model pe canalul 2 de ieșire, orizontul de validare (scenariul MULTI-PAS).....	47

Listă de tabele

5.1. Semnificația parametrilor funcției GA din MATLAB.....	27
5.2. Opțiuni de configurare ale funcției GA din MATLAB.....	27
6.2. Indicii structurali optimali determinați cu ajutorul funcției GA din MATLAB.....	31
6.3. Parametrii de configurare utilizati pentru AG în determinarea modelelor de identificare optimale obținute.....	31

Listă de acronime

AG.....	Algoritmi Genetici
ARMAX.....	Model de identificare AutoRegresiv de Medie Alunecătoare și control eXogen
ASTANK2.....	Instalație didactică hidraulică, având două rezervoare de apă interconectate
IS.....	Identificarea Sistemelor
MCMMMP.....	Metoda Celor Mai Mici Pătrate
MCMMMP-E.....	Metoda Celor Mai Mici Pătrate Extinsă
MCMMMP-MP.....	Metoda Celor Mai Mici Pătrate Multi-Pas
MCMMMP-OR	Metoda Celor Mai Mici Pătrate cu Ortogonalizarea Regresorilor
MIMO.....	<i>Multiple Input Multiple Output</i>
MISO.....	<i>Multiple Input Single Output</i>
NARMAX.....	Neliniar Auto Regresiv de Medie Alunecătoare cu control eXogen
OGS.....	Procedura de ortogonalizare Gramm-Schmidt
SISO.....	<i>Single Input Single Output</i>
SNR.....	<i>Singnal to Noise Ratio</i>

1. Introducere

Aria de interes pentru domeniul Identificării Sistemelor este vastă și a evoluat rapid încă din secolul al XVIII – lea, pornind de la contribuțiile savantului german Carl Gauss.

În ziua de astăzi, se desfășoară activități intense de cercetare științifică, care au ca obiectiv identificarea unor modele matematice și estimarea parametrilor acestora în numeroase domenii, în afară de Automatică și Tehnologiile Informatiche (de exemplu, în Sociologie, Medicină, Astronomie, Economie etc.).

Întrucât cerința determinării unui model matematic care să copieze fidel comportamentul sistemelor existente în mediul înconjurător este una nerealistă, sunt de dorit modele menite să ofere o aproximatie cu un grad de precizie cât mai ridicat. Ulterior, acestea pot fi utilizate într-un mediu de simulare, atât pentru efectuarea de teste diverse, cât și pentru proiectarea de nivel înalt a unor sisteme de control automat al proceselor respective.

Problema generală a identificării presupune o serie de pași succesivi [ȘTE2005], [SOD1989], [ȘTE2021a], începând cu analiza preliminară a procesului și scopul identificării acestuia. Astfel, va fi organizat experimentul de identificare, începând cu achiziția și prelucrarea primară a datelor. Apoi, este necesară alegerea unui model potrivit pentru sistemul în cauză (prin analiza diverselor clase de modele disponibile) și a metodei prin care acesta va fi identificat. Odată aplicată metoda aleasă, mai rămân de găsit parametrii necunoscuți ai modelului. Pentru a ne asigura că modelul determinat are o precizie convenabilă, este necesară validarea sa prin efectuarea de simulări cu alte seturi de date decât cele utilizate în etapa de identificare.

Cele mai utilizate modele de identificare sunt cele liniare. Însă, conform [ȘTE2021], când avem de-a face cu un proces care are un caracter neliniar pronunțat, nu este recomandat să îl identificăm cu ajutorul unor modele liniare. De aceea, se va încerca utilizarea unui model neliniar cât mai apropiat de dinamica procesului.

Lucrarea de față are ca obiectiv principal identificarea unei instalații hidraulice, numite ASTANK2, cu ajutorul unui model neliniar NARMAX (descriș în secțiunea următoare). Construcția modelului a necesitat implementarea *Metodei Celor Mai Mici Patrate Multi-pas* (MCMM-MP). Ulterior, întrucât indicii structurali ai modelului erau necunoscuți, a trebuit rezolvată o problemă de optimizare granulară. Pentru aceasta, a fost necesară utilizarea unei metaeuristici, capabile să determine indicii structurali optimali ai modelului. Etapa finală a proiectului a constat în simularea și validarea modelului prin analiza performanțelor acestuia. Mediul de implementare este MATLAB, cu ajutorul căruia au fost create, căutate, testate și comparate soluțiile obținute.

Motivația efectuării acestui studiu de caz este dată de dorința de a face un pas în direcția modelării neliniarităților instalației ASTANK2, ținând cont de faptul că modelul analitic al acesteia include produse de parametri fizici, exprimate, în cadrul modelului NARMAX, prin corelații încrucișate între intrări și ieșiri, fără a ne îndepărta prea mult de modelul liniar ARMAX.

În continuare, va fi detaliat întreg procesul de identificare, pe parcursul a șase capitole sugestive. După capitolul introductiv, în capitolul al doilea, am prezentat descrierea matematică și schema de principiu a modelelor SISO-NARMAX. În cel de-al treilea capitol, am abordat noțiunile teoretice fundamentale necesare implementării MCMM-MP, cu ajutorul tehnicii Ortogonalizării Regresorilor. Cel de-al patrulea capitol este dedicat formulării problemei de optimizare granulară și explicării succinte a principiului Algoritmilor Genetici. Începând cu capitolul 5, am armonizat descrierea teoretică cu aspectele practice aferente instalației ASTANK2. În cel de-al șaselea (și

ultimul capitol), am efectuat analiza modelelor optimale determinate pe baza unor seturi de date de identificare și de validare, precum și a performanțelor acestora.

2. Modele de identificare SISO-NARMAX

În inginerie, este bine cunoscut faptul că, în sprijinul proiectării, simulării și analizei sistemelor, este esențială construcția unui model matematic, pe baza datelor experimentale achiziționate. Complexitatea identificării unui sistem este influențată de caracteristicile acestuia. Clasificarea modelelor sistemiche este realizată pornind de la ideea că un sistem poate fi liniar sau neliniar, invariant sau variabil în timp continuu sau discret, cu parametri concentrați sau distribuiți. De asemenea, clasele de modele frecvent utilizate în practică sunt reprezentate prin modele având o intrare căreia îi corespunde o singură ieșire (SISO), întrucât acestea sunt cel mai ușor de identificat.

Conform teoriei *Identificării Sistemelor* (IS) [ȘTE2005], [SOD1989], [ȘTE2021a], modelarea constă, de fapt, în depistarea unor relații matematice abstracte, menite să descrie dinamica funcționării unei entități evolutive. Entitatea în cauză, privită ca o "cutie neagră", oferă observatorului anumite date experimentale, pe baza cărora vor fi construite modelele de identificare. Cu ajutorul acestora, va fi exprimată relația dintre stimul (intrarea în sistem) și reacție (ieșirea din sistem).

În general, în cazul identificării sistemelor liniare, se pune accent pe clasa ARMAX. Ecuația principală de mai jos [ȘTE2005], a atribuit clasei denumirea sa generică:

$$\begin{cases} A(q^{-1})y[n] = B(q^{-1})u[n] + C(q^{-1})e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta[n-m], \forall n, m \in \mathbb{N} \end{cases}, \quad (2.1)$$

unde: $A(q^{-1})y$ este componenta autoregresivă [AR], $C(q^{-1})e$ componenta de medie alunecătoare [MA], $B(q^{-1})u$ componenta de control exogen X, iar λ^2 este dispersia zgomotului alb Gaussian e . Polinoamele A , B , C au atât parametrii $\{a_i\}_{i=1,na}$, $\{b_i\}_{i=1,nb}$, $\{c_i\}_{i=1,nc}$, cât și indicii structurali n_a, n_b, n_c, n_k necunoscuți. Ele pot fi exprimate astfel [ȘTE2005]:

$$\begin{cases} A(q^{-1}) = 1 + a_1q^{-1} + a_2q^{-2} + \dots + a_{na}q^{-na} \\ B(q^{-1}) = b_1q^{-nk} + b_2q^{-2} + \dots + b_{nb}q^{1-nk-nb} \\ C(q^{-1}) = 1 + c_1q^{-1} + c_2q^{-2} + \dots + c_{nc}q^{-nc}. \end{cases} \quad (2.2)$$

În ceea ce privește modelele neliniare, acestea sunt reprezentate cu succes de clasa NARMAX (ARMAX neliniar). Spre deosebire de modelul anterior, ieșirea din cazul NARMAX depinde de produse dintre intrări și ieșiri din trecut. Aceste tipuri de modele pot avea grade diferite de neliniaritate, în funcție de numărul de semnale care se înmulțesc în componența ecuației principale. Modelul SISO-NARMAX de referință, având o neliniaritate de ordinul 2, poate fi scris astfel:

Identificare neliniară pe bază de modele NARMAX

$$\left\{ \begin{array}{l} A(q^{-1})y[n] + \sum_{p=0}^{P-1} A_p(q^{-1})y[n]y[n-p] = \\ = B(q^{-1})u[n] + \sum_{m=0}^{M-1} B_m(q^{-1})u[n]u[n-m] + \sum_{k=0}^{K-1} D_k(q^{-1})y[n]u[n-k] + C(q^{-1})e[n]. \\ E\{e[n]e[m]\} = \lambda^2 \delta[n-m], \quad \forall n, m \in \mathbb{N} \end{array} \right. \quad (2.3)$$

În afara polinoamelor corespunzătoare modelului ARMAX definite în (2.2), se mai definesc polinoamele:

$$\left\{ \begin{array}{l} A_p(q^{-1}) = a_{p,1}q^{-1} + a_{p,2}q^{-2} + \dots + a_{p,n_a}q^{-n_a}, \quad \forall p \in \overline{0, P-1} \\ B_m(q^{-1}) = b_{m,1}q^{-1} + b_{m,2}q^{-2} + \dots + b_{m,n_b}q^{-n_b}, \quad \forall m \in \overline{0, M-1} \\ D_k(q^{-1}) = d_{k,1}q^{-1} + d_{k,2}q^{-2} + \dots + d_{k,n_d}q^{-n_d}, \quad \forall k \in \overline{0, K-1} \end{array} \right. . \quad (2.4)$$

Complexitatea unui astfel de model provine de la numărul mare de necunoscute. Mai mult decât atât, nu sunt cunoscute gradele polinoamelor, indicii structurali majori K, M și P și nici dispersia zgomotului alb.

Atât în cazul modelelor din clasa ARMAX, cât și NARMAX, problematica universală a IS poate fi rezolvată cu ajutorul formei de regresie liniară [ȘTE2005], exprimată în urmatoarea manieră:

$$y[n] = \Phi^T[n]\theta + e[n], \quad \forall n \in \mathbb{N}, \quad (2.5)$$

unde Φ este vectorul regresorilor (având în componență să date măsurate), θ reprezintă vectorul parametrilor necunoscuți (în componență căruia nu intervene dispersia zgomotului), iar e este zgomotul alb. Potrivit [ȘTE2005], în funcție de modelul utilizat, este necesară adaparea configurației și dimensiunilor celor doi vectori din ecuația (2.5). Pentru modelul SISO-NARMAX, întrucât acesta poate fi adus la forma de regresie liniară, se pot scrie implicit cei doi vectori, după cum urmează. Astfel:

$$\theta = [\mathbf{a}^T \quad \mathbf{a}_0^T \quad \dots \quad \mathbf{a}_{p-1}^T \quad \mathbf{b}^T \quad \mathbf{b}_0^T \quad \dots \quad \mathbf{b}_{M-1}^T \quad \mathbf{d}_0^T \quad \dots \quad \mathbf{d}_{K-1}^T \quad \mathbf{c}^T]^T, \quad (2.6)$$

unde \mathbf{a} reprezintă vectorul coloană al coeficientilor polinomului A , \mathbf{b} este vectorul coloană corespunzător coeficientilor polinomului B etc. Vectorul regresorilor va fi de forma următoare, $\forall n \in \mathbb{N}$:

$$\Phi[n] = [\Phi_y^T[n] \quad \Phi_{y,0}^T[n] \quad \dots \quad \Phi_{y,p-1}^T[n] \quad \Phi_u^T[n] \quad \Phi_{u,0}^T[n] \quad \dots \quad \Phi_{u,M-1}^T[n] \quad \Phi_{yu,0}^T[n] \quad \dots \quad \Phi_{yu,K-1}^T[n] \quad \Phi_e^T[n]]^T. \quad (2.7)$$

Fiecare element din vectorul Φ poate fi explicitat separat.

$$\left\{ \begin{array}{l} \Phi_y^T[n] = [-y[n-1] \quad \cdots \quad -y[n-na]] \\ \Phi_{y,p}^T[n] = [-y[n-1]y[n-p-1] \quad \cdots \quad -y[n-na_p]y[n-p-na_p]], \forall p \in \overline{0, P-1} \\ \Phi_u^T[n] = [u[n-1] \quad \cdots \quad u[n-nb]] \\ \Phi_{u,m}^T[n] = [u[n-1]u[n-m-1] \quad \cdots \quad u[n-nb_m]u[n-m-nb_m]], \forall m \in \overline{0, M-1} \\ \Phi_{yu,k}^T[n] = [y[n-1]u[n-k-1] \quad \cdots \quad y[n-nd_k]u[n-k-nd_k]], \forall k \in \overline{0, K-1} \\ \Phi_e^T[n] = [e[n-1] \quad \cdots \quad e[n-nc]] \end{array} \right. . \quad (2.8)$$

În cazul unui sistem SISO, se poate construi schema de principiu a unui model NARMAX, prezentată în figura 2.1. Structura schemei constă în două blocuri de calcul majore. Primul, denumit NARMAX-IN, are rolul de a filtra intrarea sistemului, iar cel de-al doilea, NARMAX-OUT, filtrea ieșirea sistemului. Pe lângă aceste două blocuri, mai există filtrul reprezentat prin raportul polinoamelor C/A , cu rol în filtrarea zgomotului colorat.

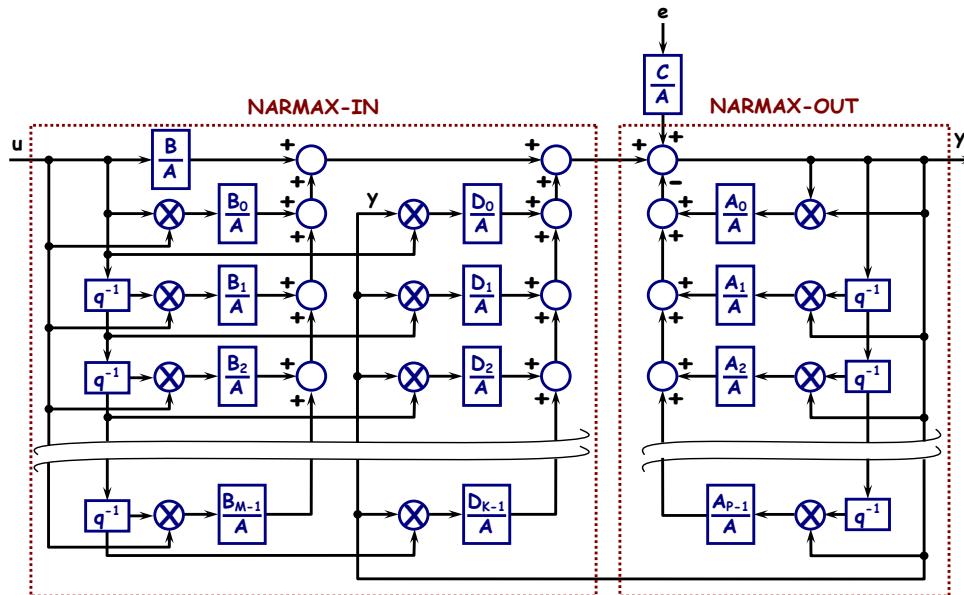


Fig. 2.1. Schema de principiu a modelului SISO-NARMAX

În cazul utilizării unui model precum NARMAX, abordarea generală constă într-o succesiune de etape:

1. Determinarea coeficienților modelului – prin intermediul unor metode de identificare adecvate.
2. Identificarea structurii modelului – determinare optimală cu ajutorul metaeuristicilor.
3. Validarea modelului – confirmarea corectitudinii și testarea performanțelor modelului.

3. Metoda de identificare a modelelor SISO-NARMAX

3.1. Noțiuni generale privind metodele de identificare

Așa cum am specificat anterior, pe baza datelor furnizate de "cutii negre", se pot identifica diverse modele matematice care aproximează comportamentul sistemelor fizice. Adesea, punctul de pornire poate fi reprezentat de ecuații

Identificare neliniară pe bază de modele NARMAX

matematice, diferențiale care descriu dinamica sistemului. În ipoteza în care aceste ecuații au anumiți coeficienți care variază pe parcursul evoluției sistemului sau au o formă mai complexă, sistemul în cauză poate să capete caracteristica de "neliniar".

Obiectivul IS poate fi îndeplinit cu ajutorul unor metode specifice. Aceasta este ca, utilizând anumite proceduri iterative sau calcule directe, să poată fi stabiliți cu precizie parametrii inițial necunoscuți ai modelului. Pentru ca acesta să poată fi atins, se pot folosi atât metode statistice preluate din Teoria Estimării, cât și metode din Teoria Optimizărilor. Conform [ȘTE2013], cele două teorii au un numitor comun. Metodele de identificare cele mai utile și interesante sunt rezultate din combinația estimării cu optimizarea.

Una dintre metodele reprezentative în acest sens este *Metoda Celor Mai Mici Pătrate* (MCMMMP). Aceasta a fost concepută plecând de la una din tehniciile fundamentale de determinare a unui model matematic, prin rezolvarea unei probleme de optimizare în care intervine un criteriu pătratic [ȘTE2005].

În cazul modelelor de regresie liniară, soluția generală a MCMMMP (2.5), poate fi prezentată după cum urmează. Având la dispoziție un set de date definit prin $D_N = \left\{ (\varphi[n], y[n]) \right\}_{n=1,N}$ și modelul de identificat, caracterizat de ecuația:

$y_M[n, \Theta] = \varphi^T[n]\Theta, \forall n \in \mathbb{N}$, se definește un criteriu pătratic bazat pe minimizarea erorii de predicție, în felul următor:

$$V(\Theta) = \sum \varepsilon^2[n, \Theta] = \sum (y[n] - y_M[n]^2) = \sum (y[n] - \varphi^T[n]\Theta^2), \forall \Theta \in \mathbb{R}^{n\Theta}. \quad (3.1)$$

În urma minimizării lui $V(\Theta)$, se va obține soluția estimată a MCMMMP [ȘTE2021a]:

$$\hat{\Theta} = \left[\sum_{n=1}^N \varphi[n] \varphi^T[n] \right]^{-1} \left[\sum_{n=1}^N \varphi[n] y[n] \right]. \quad (3.2)$$

De-a lungul timpului, au fost dezvoltate și alte metode, obținute prin adaptări sau transformări ale metodei originale [ȘTE2005].

Alegem drept exemplu *Metoda Celor Mai Mici Pătrate Extinsă* (MCMMMP-E). Aceasta este o extensie naturală a MCMMMP, utilă atât pentru identificarea modelelor din clasa ARMAX, cât și pentru clase de modele neliniare. Baza acesteia este constituită din două etape de determinare a parametrilor necunoscuți [ȘTE2005]. În ambele etape, se face apel la o altă metodă, ce aparține clasei MCMMMP (sau Metodei Variabilelor Instrumentale), ceea ce motivează conceptul "Extinsă".

Metoda Celor Mai Mici Pătrate Extinsă este adresată modelelor ce pot fi scrise în forma de regresie liniară (2.5), care prezintă dezavantajul că vectorul regresorilor, φ , include componente nemăsurabile. În cazul unui model ARMAX, de exemplu, ultima componentă a vectorului regresorilor, cea corespunzătoare zgomotului, nu poate fi măsurată. Pornind de la acest caz, se pot descrie succint cei doi pași de parcurs în cadrul MCMMMP-E [ȘTE2021a]:

1. Se face apel la un model care are vectorul regresorilor alcătuit numai din componente măsurabile, cu ajutorul căruia se estimează zgomotul ce intervine în componenta nemăsurabilă a modelului inițial.

2. Se determină parametrii originali ai modelului din vectorul inițial al regresorilor, dar care include, la acest moment, componenta nemăsurabilă estimată la pasul 1.

3.2. Descrierea Metodei Celor Mai Mici Pătrate Multi-Pas

Metoda Celor Mai Mici Pătrate Multi-Pas (MCMMMP-MP) reprezintă o adaptare a MCMMMP-E, pentru cazul modelelor neliniare, cu mențiunea că aceasta poate fi utilizată și în cazul celor liniare. Mai mult decât atât, un alt motiv pentru care această metodă este potrivită identificării unui model neliniar precum NARMAX, constă în faptul că acesta depinde de intrări și ieșiri de la pași anteriori. Atât MCMMMP-E, cât și MCMMMP-MP sunt aplicabile acelor modele în care ieșirea curentă poate fi scrisă ca o funcție de intrări, ieșiri și, eventual, zgomote din trecut [ȘTE2021a]. În mod evident, modelele identificate cu MCMMMP-MP trebuie să poată fi scrise sub forma de regresie liniară, descrisă în ecuația (2.5).

Strategia generală de identificare prin MCMMMP-MP presupune două etape: inițierea și rafinarea. Cea de-a doua etapă include mai mulți pași, de unde apare și denumirea "Multi-Pas" [ȘTE2021a]. Astfel:

1. *Inițierea*. Se identifică un model aproximant (auxiliar), grosier. Pentru identificarea sa, se ignoră complet zgomotul alb din vectorul regresorilor și se utilizează o metodă din clasa MCMMMP (în cazul NARMAX am utilizat MCMMMP cu Ortogonalizarea Regresorilor, așa cum va fi descris în secțiunea 3.3).
2. *Rafinarea*. Într-un proces iterativ, se rafinează modelul de identificare:
 - a. Se estimează valorile zgomotului alb cu ajutorul modelului auxiliar rezultat în urma etapei 1.
 - b. Având la dispoziție zgomotul alb estimat, se poate identifica modelul original în care acestea intervin.
 - c. Se redetermină modelul auxiliar. Deoarece acesta are o precizie scăzută, se apelează la filtrarea intrării și ieșirii cu un filtru invers de zgomot. La fiecare iterație, zgomotul alb estimat la pasul a. se apropiă tot mai mult de un zgomot alb veritabil, deși acesta nu va fi niciodată un zgomot alb pur, ci tot unul colorat. Totuși, prin filtrări repetitive, se încearcă mărirea benzii sale de frecvență, unde el este aproximativ constant, în speranța îmbunătățirii preciziei modelului.

Etapa de rafinare se va încheia prin impunerea unui test de precizie. Mai precis, se dorește ca eroarea medie minimă dintre proces și model să fie sub un anumit prag de eroare predefinit.

Algoritm 3.1. Procedura numerică aferentă MCMMMP-MP [ȘTE2021a]:

Initializare.

1. Se formează modelul auxiliar, în urma eliminării componentelor de zgomot.
2. Se identifică modelul auxiliar (aproximant grosier).

Buclă iterativă. Cât timp precizia impusă nu este atinsă, pentru un $k \geq 0$:

1. Pe întreg orizontul de măsură, exceptând momentul final, se estimează valorile zgomotului.
2. Se construiește vectorul estimat al regresorilor de zgomot.

3. Se identifică modelul neliniar curent. La acest pas, vectorul regresorilor este cel original, iar metoda utilizată pentru identificare este *MCMMP cu Ortogonalizarea Regresorilor* (MCMMP-OR), descrisă în secțiunea următoare.
4. Pe întregul orizont de măsură, se evaluatează eroarea curentă dintre proces și model.
5. Se filtrează regresorii și ieșirile cu filtrul invers de zgomot, pentru a reactualiza vectorul regresorilor al modelului auxiliar la fiecare iterație.
6. Cu ajutorul noilor semnale, se rafinează modelul aproximant. Se aplică, din nou, MCMMP-OR.
7. Se trece la următoarea iterație: $k \leftarrow k + 1$.

Observații privind metoda analizată [STE2021a]:

- Etapa de inițiere include inițializarea și pașii 1-5 ai buclei iterative, parcursi pentru prima dată. Etapa de rafinare se realizează începând cu pasul 6 al buclei iterative și continuă cu ceilalți pași, până la atingerea pragului de precizie impus. Parcurgerea repetată a pasului 6 justifică sintagma "Multi-Pas" adaugată numelui MCMMP.
- Complexitatea și numărul termenilor liniari influențează viteza de convergență a metodei. În cazul unui model liniar având același număr de parametri, viteza ar fi mai redusă.
- Consistența estimatiilor se poate analiza mai ușor dacă intrarea este reprezentată de un zgomot alb Gaussian care nu este corelat cu zgomotul alb exogen.
- În general, MCMMP-MP constituie o soluție eficientă de identificare pentru o gamă largă de modele neliniare, cu condiția ca acestea să poată fi exprimate în forma de regresie liniară.

3.3. Tehnica Ortogonalizării Regresorilor

În secțiunea precedentă a fost menționată utilizarea Metodei Celor Mai Mici Pătrate cu Ortogonalizarea Regresorilor (MCMMP-OR), pentru identificarea modelului aproximant grosier din cadrul MCMMP-MP. Această adaptare distinctă a MCMMP ajută la evitarea condiționării numerice slabe prezentă în metoda originală [STE2021a].

Procedeul care stă la baza MCMMP-OR este cel al ortogonalizării *Gramm-Schmidt* (OGS) [STE2021a]. Mai precis, se vor ortogonaliza coloanele matricii regresorilor, astfel încât vectorul parametrilor estimati să nu sufere modificări. Scopul procedeului OGS este de a obține un set de vectori coloană ortonormali. Se pornește de la coloanele inițiale ale matricii regresorilor, care sunt liniar independente, dar nu neapărat ortogonale. Apoi, se ortogonalizează, rând pe rând, fiecare coloană, până la ultima din matrice.

Algoritmul OGS este prezentat succint în cele ce urmează.

Algoritm 3.2. Procedeul de ortogonalizare Gramm-Schmidt

Date de intrare. Matricea regresorilor, notată cu Φ , împreună cu numărul de linii N și de coloane n .

Date de ieșire. Matricea regresorilor ortogonalizată, notată Φ^\perp .

Initializare. Matricea Φ^\perp este inițial nulă, apoi prima coloană din matricea inițială devine prima coloană din matricea ortogonalizată.

Bucă iterativă. Pentru toate coloanele $m \in \overline{2, n}$ ale lui Φ^\perp :

- Se construiește următoarea coloană din Φ^\perp :

$$\Phi_m^\perp = \Phi_m - \sum_{k=1}^{m-1} \frac{\langle \Phi_m, \Phi_k^\perp \rangle}{\| \Phi_k^\perp \|^2} \times \Phi_k^\perp.$$

Odată realizată ortogonalizarea, se poate trece la algoritmul general al MCMMP-OR, care este destul de rapid, stabil numeric și eficient [STE2021a]:

Algoritm 3.3. Procedura numerică aferentă MCMMP-OR

Date de intrare. Datele achiziționate din proces $D_N = \{(\varphi[n], y[n])\}_{n=\overline{1,N}}$ și indicele structural al modelului de identificare n_θ .

Date de ieșire. Vectorul parametrilor optimali ai modelului $\hat{\Theta}_{n_\theta}$ și dispersia zgromotului alb λ^2 .

Initializare.

1. Pe baza componentelor din vectorul regresorilor modelului, se formează matricea regresorilor, prin stivuire.
2. Coloanele matricii regresorilor se ortogonalizează folosind procedeul OGS descris anterior.
3. Se formează vectorul de date: $\mathbf{Y} = [y[n]]_{n=\overline{1,N}}$.

4. Se estimează parametrul optimal de indice maxim: $\hat{\Theta}_{n_\theta} = \frac{\langle \mathbf{Y}, \Phi^\perp \rangle}{\| \Phi_{n_\theta}^\perp \|^2}$.

1. Bucă iterativă. Pentru $m \in \overline{n_\theta - 1, 1}$: (parametrii optimali vor fi estimati în ordinea inversă a indicilor)

1. Se calculează parametrul curent:

$$\hat{\Theta}_{n_\theta} = \frac{\langle \mathbf{Y}, \Phi_m^\perp \rangle - \sum_{k=m+1}^{n_\theta} \langle \Phi_k, \Phi_m^\perp \rangle \times \hat{\Theta}_k}{\| \Phi_m^\perp \|^2}.$$

2. Indicele curent se decrementează: $m \leftarrow m - 1$.
2. Se estimează dispersia zgromotului alb: $\lambda^2 = \frac{1}{\gamma_N} \times \| \mathbf{Y} - \Phi \hat{\Theta} \|^2, \gamma \in \{N, N - n_\theta\}$.

4. Determinarea optimal-metauristică a indicilor structurali

4.1. Motivația necesității utilizării unei metauristică

Odată stabilită metoda de identificare a parametrilor necunoscuți, următoarea problemă de rezolvat este cea a determinării indicilor structurali. Soluția constă într-o metodă de căutare a valorilor optime ale acestor indici pentru care modelul are cel mai

bun comportament. Faptul că acestea nu pot fi găsite la întâmplare de către utilizator constituie motivul utilizării unei metaeuristici.

Metaeuristicile constituie o alternativă a metodelor tradiționale de determinare a punctului de optim. Acestea au fost create în sprijinul tehniciilor de optimizare, pentru a extinde capacitatea de determinare a punctelor optimale în cazul unor criterii cu aspect fractal. Limitările metodelor clasice pot proveni din neliniaritatea sau nediferențialitatea funcției obiectiv, din posibilitatea ca gradientul funcției să fie nedefinit sau din complexitatea variabilelor sale. Pentru a evita aceste obstacole, se poate face apel la *Algoritmii Genetici* (AG), deoarece acestia nu utilizează informații despre gradientul funcției obiectiv și și-au dovedit eficacitatea în numeroase aplicații. În acest caz, căutarea este efectuată cu ajutorul unui set de reguli bine definite, bazat pe operații genetice aplicabile cromozomilor informatici, plecând de la inițializări aleatoare [MIT1995], [SOA2006], [STE2014], [LUT2014].

4.2. Metauristică Algoritmilor Genetici

Algoritmii Genetici reprezintă metode de optimizare evoluționare, inspirate din biologie, bazate pe mecanismele de selecție naturală descrise de către Charles Darwin. Scopul acestora este reprezentat de determinarea celei mai bune soluții a problemei de optimizat. Pentru acesta este fundamentală definirea unei funcții cost (sau criteriu) care trebuie optimizată (optimizat).

Construcția acestui tip de algoritmi are drept fundament concepte provenite din Genetică. Dintre acestea, cele mai importante sunt [POP2021]:

- *Genele*, care sunt reprezentate de fiecare parametru necunoscut al problemei în cauză; de regulă, reprezentarea numerică a acestora este binară (pe biți).
- *Cromozomul*, care constă într-un set de gene, concatenate, însemnând totalitatea parametrilor necunoscuți ai problemei de optimizat.
- *Individul*, care reprezintă o instanță de cromozom.
- *Populația*, care este alcătuită dintr-un set de indivizi, având o dimensiune stabilită a priori.
- *Operatorii genetici* definiți astfel:
 - *Încrucișarea* = operația principală de obținere a doi *descendenți* pe baza caracteristicilor moștenite de la ambii părinți participanți.
 - *Mutația* = operația de modificare aleatoare a bițiilor din cadrul genelor unui cromozom.
 - *Inversiunea* = operația de înlocuire a unui sir consecutiv de biți (din una sau mai multe gene) cu versiunea sa în oglindă, adică "inversată" ca manieră de citire.

Pentru diminuarea posibilității ca algoritmul să conveargă prea rapid către un maxim (de regulă, local), mutația și inversiunea introduc, cu anumite probabilități (sensibil mai mici decât probabilitatea de încrucișare, totuși), anumite erori în valorile cromozomilor, permitând, astfel, căutarea optimului într-o zonă îndepărtată față de cea curentă. Pe de altă parte, o diversitate prea mare a populației determină incapacitatea acesteia de a converge către un punct optimal și poate conduce la un comportament oscilant al procedurii de căutare. Prin urmare, trebuie găsit un echilibru între convergența către optim (numită „capacitate de exploatare” a unei vecinătăți înguste din spațiul de căutare) și diversitatea populației (numită „capacitate de explorare” a întregului spațiu de căutare).

Alegerea cromozomilor care pot fi afectați de operații genetice se realizează printr-un criteriu de selecție. Acesta se definește folosind funcția cost ce trebuie optimizată. Există numeroase criterii de selecție definite în literatura de specialitate [MIT1995], [ȘTE2014]. Un criteriu frecvent utilizat este cel bazat pe funcția de reprezentativitate, proporțională cu funcția criteriu.

Principiul care stă la baza AG poate fi prezentat sub formă generală, prin următoarele etape [POP2021]:

1. Inițializarea aleatoare a populației.
2. Evaluarea funcției cost pentru fiecare cromozom din componența populației.
3. Selectia cromozomilor care pot participa la operațiile genetice.
4. Aplicarea operației de încrucișare asupra cromozomilor selectați în acest scop.
5. Aplicarea operației de mutație și/sau inversiune asupra unora dintre cromozomii rezultați după încrucișare.
6. Memorarea cromozomului având cea mai bună valoare a funcției cost. După un anumit număr de iterații, acesta poate fi considerat punctul de optim căutat.

Succesul unui AG depinde de doi factori principali: alegerea parametrilor de configurare și efectuarea unui compromis explorare-exploatare. Conform [ȘTE2014], configurarea unui AG este influențată de numărul de parametri aleși în faza de proiectare. Provocarea utilizatorului este de a seta corespunzător numeroșii parametri de configurare ai AG, în funcție de specificul fiecărei aplicații. Nu este imperios necesar să fie utilizați toți parametrii, dar un AG trebuie testat prin rulări repetitive, eventual cu configurații inițiale distințe.

De asemenea, pentru a putea implementa un AG, este necesar să se găsească răspunsuri la următoarele întrebări [ȘTE2014]:

- Care este componența cromozomului?
- Cum ar trebui setată populația inițială?
- Care sunt cele mai potrivite setări pentru configurare?
- Care este cea mai bună condiție de oprire a algoritmului?

Pe parcursul implementării, pot apărea diferite probleme tehnice. Conform mai multor opinii ale oamenilor de știință, construcția și implementarea unui AG "bun" (eficient) constituie una dintre cele mai dificile sarcini [ȘTE2014]. Cu toate acestea, există un spectru larg de alte proceduri metaeuristice, bazate pe comportamente ale speciilor din natură, care constituie alternative mai mult sau mai puțin complexe pentru AG [ȘTE2014].

În esență, teoria AG este fascinantă. Deși găsirea unei soluții (convergență) nu este garantată, iar rezultatele obținute depind de experiența dezvoltatorului și/sau de modul în care problema de optimizare se potrivește cu metaeuristica aleasă, AG au un avantaj major: pot fi utilizați pentru a rezolva o paletă foarte largă de probleme de optimizare [POP2021].

4.3. Formularea problemei de optimizare

Așa cum am menționat în secțiunea 4.2, problema de optimizare poate fi formulată în contextul unei funcții cost [ȘTE2014]:

$$f : S \rightarrow \mathbb{R}, \quad (4.1)$$

unde S reprezintă spațiul de căutare, care este o submulțime mărginită a lui \mathbb{R}^{nx} , cu nx - numărul variabilelor de optimizare.

De ce ar fi necesară acordarea unei atenții deosebite funcției cost? În primul rând, aceasta are o variație fractală, aşadar cu multe extreme locale. În al doilea rând, derivatele sale, dacă există, sunt dificil de evaluat. În general, criterul f este continu sau derivabil la nivel local, dar această proprietate nu se extinde și la nivel global. De altfel, criteriul poate fi evaluat, pentru fiecare punct x al spațiului de căutare S , cu ajutorul unor expresii matematice cunoscute printr-o anumită procedură numerică. Prin urmare, pentru problema de optimizare, care constă în găsirea optimului global al criteriului f și, deci, a punctului de optim $x^{opt} \in S$, scrisă sub forma:

$$x^{opt} = \arg \underset{x \in S}{\text{opt}} f(x). \quad (4.2)$$

Pentru a rezolva problema (4.2), se poate efectua fie o căutare exhaustivă a spațiului S (dacă acesta are dimensiuni reduse), fie o căutare aleatoare fără o strategie anume (ceea ce înseamnă folosirea Metodei Monte-Carlo [STE2014]), fie o căutare după o strategie specifică unei anumite metaeuristici. De regulă, întrucât căutarea trebuie să aibă o durată convenabilă, doar un anumit subset de valori din S poate fi testat. Totuși, deoarece este de dorit să nu fie ratat punctul de optim în căutare, acest subset trebuie să conțină un număr suficient de mari de puncte pentru evaluare.

Necesitatea rezolvării problemei (4.2), a condus, implicit, la implementarea de metaeuristici, care evită căutarea exhaustivă. Deși, prin evitarea unei astfel de căutări, ar putea fi ratat optimul global, se poate spera la o compensare prin creșterea vitezei de căutare, precizia rămânând suficient de bună. În acest caz, căutarea optimului simulează, adesea, comportamentul unui sistem biologic care are un mecanism întrinsec de optimalitate [STE2014].

Potrivit [LUT2014], în scopul rezolvării problemei de optimizare cu ajutorul unui AG (4.2), putem apela din nou la filosofia "cutiei negre". De această dată, ieșirea este valoarea optimă a unei funcții cost care se obține pentru o anumită combinație de parametri. Pentru intrare, însă, trebuie să fie bine cunoscută problema în cauză și adaptată corespunzător, aşa cum sugerează figura 4.1.



Fig. 4.1. Adaptarea AG la problema de optimizare

Funcția cost specifică unei anumite probleme de optimizare se poate defini odată ce a fost parcursă etapa de interpretare genetică a problemei. Aceasta presupune stabilirea clară a parametrilor pe care dorim să-i determinăm și care influențează funcția cost.

5. Studiu de caz: identificarea MISO-NARMAX a instalației ASTANK2

5.1. Descrierea instalației ASTANK2

Întregul studiu se concentrează pe instalația numită ASTANK2 [CUL2015], proiectată de firma ASTI Automation, în scopuri educaționale, privind cercetarea în direcția modelării, simulării, identificării și controlului sistemelor neliniare. Aceasta este un sistem hidraulic format din două rezervoare având aceeași înălțime, dar configurații

diferite. În figura 5.1, se poate observa reprezentarea schematică a sistemului ASTANK2 [CUL2015].

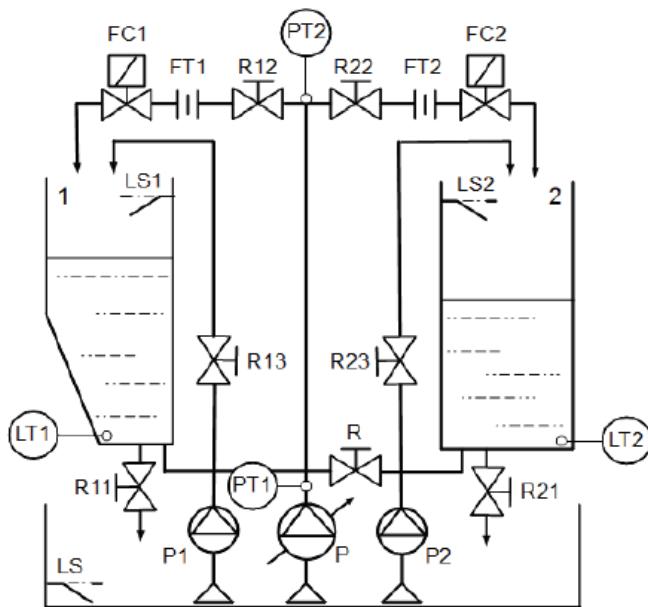


Fig.5.1. Schema instalației ASTANK2 (preluată din [CUL2015], cu acordul autorilor).

Deosebirea evidentă dintre cele două tipuri de rezervoare este dată de forma lor. Secțiunea rezervorului din partea stângă este variabilă, datorită peretelui său înclinat, în timp ce rezervorul din dreapta are formă paralelipipedică obișnuită. În acest sistem, neliniaritatea provine tocmai de la forma primului rezervor.

Cu ajutorul unei pompe și a unei rețele de distribuție, instalația este alimentată cu apă provenită de la un al treilea rezervor.

Prin intermediul traductoarelor de nivel LT1 și LT2, este măsurat nivelul apei corespunzător fiecărui bazin. În figură, LS1, LS2 și LS sunt senzori de nivel; primii doi indică umplerea bazinelor, iar cel de-al treilea semnalează limita inferioară a nivelului apei din rezervorul de alimentare. Pompa P are rolul de a distribui apă din cel de-al treilea rezervor, de la nivelul inferior, de-a lungul conductei verticale din mijloc, către celelalte rezervoare, fiind actionată de un invertor. În sprijinul lui P, există alte două pompe auxiliare, P1 și P2, cu scopul de a permite adăugarea unui volum suplimentar de apă în fiecare bazin, prin conductele verticale secundare. Notațiile FT1 și FT2 indică cei doi senzori de debit, iar FC1 și FC2 reprezintă două electrovalve controlate în tensiune, cu rol în varierea debitului ce intră în cele două rezervoare.

În cadrul sistemului, pot fi introduse perturbații. Acest lucru este realizat prin intermediul pompelor P1 și P2, cu mențiunea că debitul perturbat din conducte poate fi controlat cu ajutorul robinetelor manuali R13 și R23.

Parametrii măsuраti ai sistemului sunt, de fapt, înălțimile coloanelor de lichid din cele trei rezervoare prezentate. Aceștia depind de următorii parametri de intrare în sistem: tensiunea aplicată fiecărei dintre electrovalvele FC1 și FC2, tensiunea asupra pompei P și setările efectuate asupra pompelor secundare (dacă acestea sunt pornite sau nu).

Un model matematic care ține cont de toate componentele specifice ale instalației ASTANK2 poate fi inadecvat pentru aproximarea comportamentului real al întregului proces. Motivul este faptul că dinamica de curgere a rezervoarelor este influențată de constrângerile fizice. În conformitate cu [CUL2017], în urma unor investigații experimentale, a fost descoperit faptul că instalația are anumite limite practice date de:

- Lungimile scurte ale conductelor orizontale. Ele influențează turbulentele din procesul de curgere. Acest aspect implică îngreunarea estimării constantelor de curgere cu o precizie suficient de bună, ceea ce îngreunează semnificativ modelarea analitică a sistemului hidraulic.
- Debitele de admisie care provin de la pompa P către rezervoare. Acestea pot fi reglate cu ajutorul tensiunilor din electrovalve, dar volumul de apă din bazine nu este neapărat direct proporțional cu deschiderea electrovalvelor. Când există o diferență semnificativă între cele două semnale de intrare (de peste 4V), debitul de admisie al celui de-al doilea rezervor devine neglijabil, însemnând că nu va curge apă prin conducta corespunzătoare acestuia. Așadar, avem de-a face cu un caz în care numai comportamentul conductei din partea dreaptă a figurii 5.1 poate fi modelat. De aceea, pentru identificarea unor modele precise ale conductelor, ar trebui luate în calcul toate combinațiile de tensiuni aplicate pe cele două electrovalve.
- Variația diferită a debitelor de apă în conducte. Deși secțiunile conductelor sunt egale, debitele sunt diferite la combinații de tensiuni distincte (acestea nu pot furniza de fiecare dată aceeași formă a unui model matematic al conductelor). Prin urmare, este necesară testarea tuturor combinațiilor de tensiuni.
- Tensiunea pompei principale. Inclusiv limitele reale ale acesteia depind de combinații ale tensiunilor electrovalvelor. Pentru combinațiile testate, valorile limită ale tensiuni pompei au fost fixate experimental, astfel încât să fie evitat fenomenul de rezonanță.
- Riscul ca electrovalvele să se deterioreze. La reglarea tensiunii din electrovalve, prin modificarea curentului de intrare, nu este indicat ca amplitudinea modificării să depășească 3V.

De-a lungul timpului, au fost analizate mai multe abordări de modelare/identificare a instalației, prin dezvoltarea de modele analitice sau a unor combinații de metode analitice și experimentale, așa cum este raportat în [CUL2015], [STE2020], [STE2021b]. Pentru obținerea unui model cât mai precis, variațiile semnalelor de intrare au fost limitate de constrângeri fizice alese experimental, cu scopul de a evita situațiile de funcționare necorespunzătoare a instalației. Prin urmare, dintre cele 3 semnale de intrare în sistem, reprezentate de tensiunea U a pompei principale și cele două tensiuni aplicate pe electrovalve, U a fost menținută la o valoare constantă (8 V). Tensiunile electrovalvelor au fost generate ca semnale pseudo-aleatoare cu o distribuție Gaussiană, în intervalul [5,10] V [CUL2015]. Așadar, putem privi, într-o manieră simplificată, instalația ASTANK2 ca un sistem cu două intrări și două ieșiri. Semnalele de ieșire sunt reprezentate de următoarele două stări măsurabile: nivelul apei din primul rezervor (y_1) și nivelul apei din cel de-al doilea rezervor (y_2). Semnalele de intrare u_1 și u_2 sunt reprezentate de tensiunile aplicate la nivelul electrovalvelor FC1 și FC2, așa cum ilustrează figura 5.2.

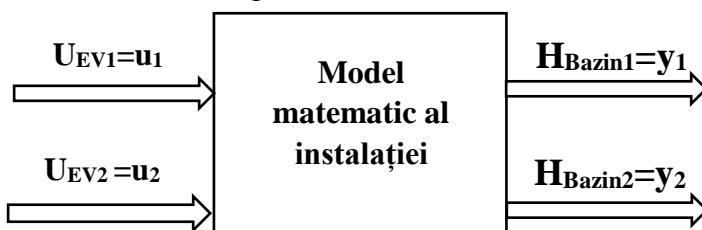


Fig. 5.2. Schema conceptuală simplificată a instalației ASTANK2

Astfel, ajungem la concluzia că procesul instalației este multivariabil, cu mai multe intrări și mai multe ieșiri (MIMO).

5.2. Identificarea instalației ASTANK2

5.2.1. ASTANK2 ca proces de tip MISO

În ansamblu, un sistem MIMO reprezintă un proces cu $nu \times ny$ canale de intrare/ieșire [CUL2015]. Acest tip de proces multivariabil poate furniza ny seturi de date măsurate, având o anumită lungime $N \in \mathbb{N}^*$ și forma generală: $D_{N,k} = \{u_1[n], u_2[n], \dots, u_{nu}[n], y_k[n]\}_{n \in \overline{1,N}}$, $k \in \overline{1,ny}$. Deși numărul de canale poate fi redus, adesea, identificarea unor astfel de sisteme a reprezentat o provocare. Pentru aceasta, putem aproxima un sistem MIMO cu ajutorul mai multor sisteme având mai multe intrări și o singură ieșire (MISO), câte unul corespunzător fiecărei ieșiri, subseturile de date fiind utilizate separat.

Astfel, instalația ASTANK2 poate fi modelată cu ajutorul a două blocuri MISO. Practic, procesul global MIMO va fi descompus în două subprocese MISO. La rândul lor, procesele MISO au în componentă subprocese de tip SISO, aşa cum ilustrează figura 5.3. Subliniem, totuși, că modelul MISO este doar aproximat cu ansamblul celor două modele MISO, nefiind echivalent cu acesta.

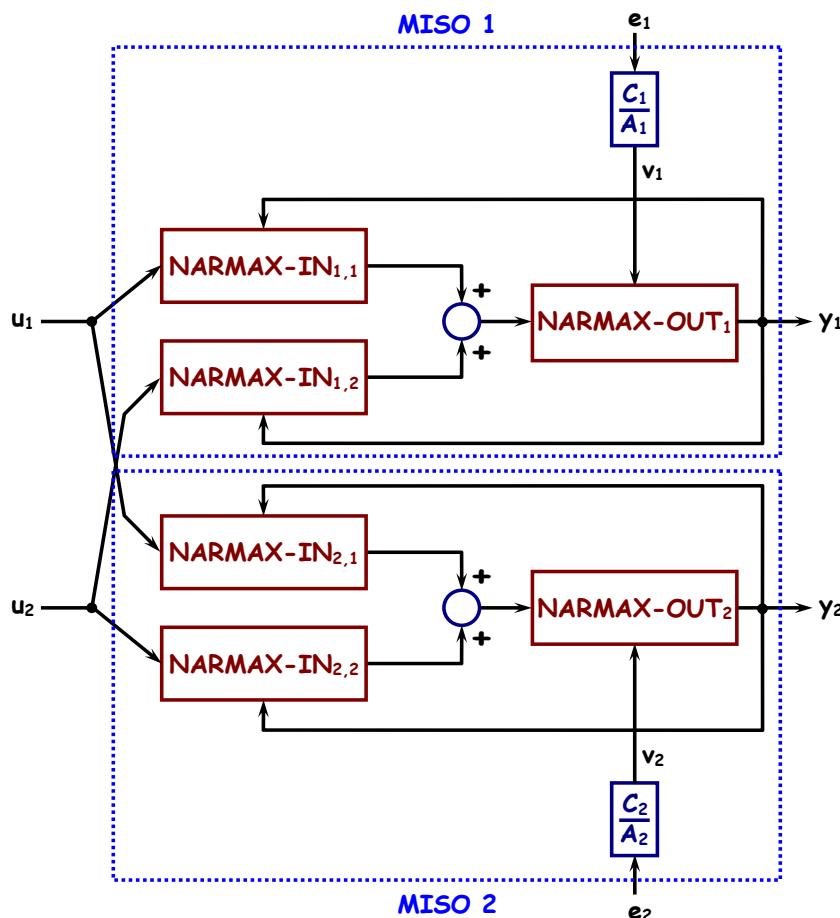


Fig. 5.3. Schema de simulare a modelului multi-MISO-NARMAX, asociat instalației ASTANK2.

Mai mult decât atât, deoarece instalația are un comportament afectat de neliniarități, putem utiliza un model neliniar pentru a reuși să îi aproximăm dinamica.

Identificare neliniară pe bază de modele NARMAX

În capitolul 2, a fost prezentat modelul SISO-NARMAX. Studiul de caz se concentrează pe utilizarea acestui tip de model, extins la cazul MISO-NARMAX, pentru identificarea instalației hidraulice. Motivația alegerii acestui tip de model o constituie faptul că modelul analitic al instalației include corelații încrucișate între intrări, ieșiri și între intrări și ieșiri. Prin urmare, schema corespunzătoare figurii 2.2, poate fi adaptată pentru ASTANK2, aşa cum sugerează figura 5.3.

Practic, la fiecare ieșire, există două blocuri de tip NARMAX-IN (câte unul pentru fiecare dintre intrările u_1 și u_2) și un singur bloc de tip NARMAX-OUT. De această dată, indicii structurali majori ai modelului NARMAX, K , M și P (din ecuația 2.3), care erau deja necunoscuți, se transformă în alte două seturi de indici necunoscuți:

- K este înlocuit de $K_{1,1}, K_{1,2}, K_{2,1}, K_{2,2}$;
- M este înlocuit de $M_{1,1}, M_{1,2}, M_{2,1}, M_{2,2}$;
- P este înlocuit de P_1, P_2 .

Primul indice din structura fiecărui parametru necunoscut este corespunzător canalului de ieșire aferent, iar cel de-al doilea indice reprezintă intrarea sau ieșirea între care se realizează corelațiile încrucișate la un anumit moment de timp.

Plecând de la forma generală a modelului NARMAX din ecuația (2.3), adaptarea pentru instalația hidraulică, poate fi rescrisă sub forma:

CANAL DE IEȘIRE 1:

$$\left\{ \begin{array}{l} A_1(q^{-1})y_1[n] + \sum_{p=0}^{P_1-1} A_{1,p}(q^{-1})y_1[n]y_1[n-p] = \\ = B_{1,1}(q^{-1})u_1[n] + \sum_{m=0}^{M_{1,1}-1} B_{1,1,m}(q^{-1})u_1[n]u_1[n-m] + \sum_{k=0}^{K_{1,1}-1} D_{1,1,k}(q^{-1})y_1[n]u_1[n-k] + \\ + B_{1,2}(q^{-1})u_2[n] + \sum_{m=0}^{M_{1,2}-1} B_{1,2,m}(q^{-1})u_2[n]u_2[n-m] + \sum_{k=0}^{K_{1,2}-1} D_{1,2,k}(q^{-1})y_1[n]u_2[n-k] + C_1(q^{-1})e_1[n] \\ E\{e_1[n]e_1[m]\} = \lambda_1^2 \delta[n-m], \quad \forall n, m \in \mathbb{N}. \end{array} \right. \quad (5.1)$$

CANAL DE IEȘIRE 2:

$$\left\{ \begin{array}{l} A_2(q^{-1})y_2[n] + \sum_{p=0}^{P_2-1} A_{2,p}(q^{-1})y_2[n]y_2[n-p] = \\ = B_{2,1}(q^{-1})u_1[n] + \sum_{m=0}^{M_{2,1}-1} B_{2,1,m}(q^{-1})u_1[n]u_1[n-m] + \sum_{k=0}^{K_{2,1}-1} D_{2,1,k}(q^{-1})y_2[n]u_1[n-k] + \\ + B_{2,2}(q^{-1})u_2[n] + \sum_{m=0}^{M_{2,2}-1} B_{2,2,m}(q^{-1})u_2[n]u_2[n-m] + \sum_{k=0}^{K_{2,2}-1} D_{2,2,k}(q^{-1})y_2[n]u_2[n-k] + C_2(q^{-1})e_2[n] \\ E\{e_2[n]e_2[m]\} = \lambda_2^2 \delta[n-m], \quad \forall n, m \in \mathbb{N}. \end{array} \right. \quad (5.2)$$

În vederea pregătirii experimentului de identificare, au fost achiziționate mai multe seturi de date de la instalație, corespunzătoare fiecărui canal de ieșire. Fiecare set de date conține atât date de identificare, cât și date de validare, de forma [CUL2015]:

$$\begin{cases} D^{id} = \left\{ u_1^{id}[n], u_2^{id}[n], \dots, u_{nu}^{id}[n], y^{id}[n] \right\}_{n \in \overline{1, N}} \\ D^{va} = \left\{ u_1^{va}[n], u_2^{va}[n], \dots, u_{nu}^{va}[n], y^{va}[n] \right\}_{n \in \overline{1, N}} \end{cases} . \quad (5.3)$$

Sunt necesare două tipuri de date, deoarece identificarea unui model presupune stimularea atât a acestuia, cât și a procesului asociat, cu semnale de intrare diferite față de cele utilizate pentru obținerea primului set de date de identificare. Este de interes compararea ieșirilor rezultate în fiecare caz, pentru a putea trage o concluzie despre validitatea modelului.

5.2.2. Implementarea metodei de identificare

Întreaga construcție a modelului, constând în etapa de identificare, de căutare optimală a indicilor și de simulare, a fost realizată cu ajutorul mediului de programare MATLAB. Motivul principal este acela că platforma MATLAB oferă inginerilor implicăți în activități de cercetare o multitudine de perspective de implementare și testare. Mai mult decât atât, pentru un Tânăr inginer, MATLAB reprezintă unul dintre cele mai confortabile limbaje, mai ales când există experiență anterioară, dobândită în cadrul studiilor universitare.

Astfel, în sprijinul procedeului de identificare a modelului matematic neliniar al instalației ASTANK2, am implementat metoda MCMMMP-MP descrisă pe scurt capitolul 3. Funcția principală a metodei depinde de alte două rutine separate: prima implementează procedeul OGS (conform subsecțiunii 3.3.1), iar a doua implementează MCMMMP-OR (conform subsecțiunii 3.3.2), apelând-o pe prima. Scopul este determinarea modelului global al instalației, ai cărui parametri necunoscuți vor trebui determinați pentru a putea trage o concluzie despre performanțele acestuia.

Etapele parcurse în implementarea metodei de identificare sunt:

1. Preluarea în mediul informatic a unui set cu date achiziționate de la instalație. Experimentul este desfășurat pe date brute, afectate de zgomot, fără o filtrare anterioară.
2. Construcția matricii regresorilor a modelului instalației, notată cu Φ . Fie căruia polinom din cadrul ecuațiilor (5.1) și (5.2) îi corespunde câte un vector de tipul celor din ecuația (2.8). După construcția vectorilor pe coloane, până la gradele maxime corespunzătoare na, na_p, nb, nb_m, nd_k , matricea regresorilor se formează prin concatenarea tuturor acestora.
3. Identificarea modelului aproximant grosier, pe care îl voi numi generic Θ_{aprox} . Identificarea acestuia a presupus aplicarea metodei MCMMMP-OR, corespunzătoare algoritmului 3.3. În pasul 2 al algoritmului, a fost necesară ortogonalizarea matricii Φ , cu ajutorul algoritmului 3.2.
4. Identificarea iterativă a modelului neliniar curent, Θ_{curent} . Odată identificat modelul auxiliar, se trece la construcția matricii regresorilor corespunzătoare zgomotului. Astfel, prin concatenarea matricii inițiale a regresorilor cu cea a zgomotului, s-a putut aplica din nou MCMMMP-OR pentru identificare, din care rezultă, de această dată, Θ_{curent} . După acest pas, se rafinează modelul auxiliar: se filtrează Φ și vectorul de date \mathbf{Y} și se utilizează din nou MCMMMP-OR pentru identificarea nouui Θ_{aprox} . Această procedură este repetată până când este îndeplinit criteriul de stop: eroarea finală dintre proces și model, evaluată

pe întregul orizont de măsură, să fie mai mică decât un prag de precizie impus (cărui i s-a atribuit valoarea 10^{-3}).

Modelul global optimal este obținut la finalul acestei proceduri iterative.

Din momentul în care este determinat modelul optimal, se poate trece la următoarea fază importantă a întregului proces de identificare neliniară: determinarea indicilor structurali optimali ai modelului instalației ASTANK2, prin utilizarea AG.

5.3. Adaptarea Algoritmilor Genetici

5.3.1. Definirea funcției cost specifice

Când vine vorba de astfel de studii de cercetare, obiectivul general este ca, în cazul în care se obțin modele optimale, acestea să fie simultan identificate și validate. Prin urmare, criteriul de optimizare având scopul de a determina indicii structurali ai modelului trebuie să fie construit pe baza ambelor seturi de date din ecuația (5.3) [CUL2015].

Funcția cost va avea care va fi definită pe raportul semnal–zgomot (SNR) al fiecărui canal. Problema de optimizare constă în maximizarea acestei funcții cost, prin varierea indicilor structurali necunoscuți în diferite intervale de căutare. După identificarea modelului NARMAX, se poate estima SNR după cum urmează:

$$\text{SNR}_1^{\text{ID}} = \frac{\sqrt{\frac{1}{N} \sum_{n=1}^N \tilde{y}_1^2[n]}}{\hat{\lambda}_1}, \quad \text{SNR}_2^{\text{VA}} = \frac{\sqrt{\frac{1}{N} \sum_{n=1}^N \tilde{y}_2^2[n]}}{\hat{\lambda}_2}, \quad (5.4)$$

în cadrul cărora : $\tilde{y}_j \equiv \tilde{y}_j - \frac{1}{N} \sum_{n=1}^N \tilde{y}_j[n]$, iar $\hat{\lambda}_j$ este dispersia erorii de model .

Fiecare SNR variază odată cu indicii structurali. De asemenea, fiecare set de date (identificare, validare) conduce la câte un SNR pentru fiecare dintre cele două canale de ieșire. Vom numi funcția cost *fitness* deoarece aceasta se poate exprima procentual astfel [STE2021a]:

$$F[\gamma] = 100 \left[\frac{\eta_1^{\text{ID}}}{1 + \frac{\mu_1^{\text{ID}}}{\text{SNR}_1^{\text{ID}}[\gamma]}} + \frac{\eta_1^{\text{VA}}}{1 + \frac{\mu_1^{\text{VA}}}{\text{SNR}_1^{\text{VA}}[\gamma]}} + \frac{\eta_2^{\text{ID}}}{1 + \frac{\mu_2^{\text{ID}}}{\text{SNR}_2^{\text{ID}}[\gamma]}} + \frac{\eta_2^{\text{VA}}}{1 + \frac{\mu_2^{\text{VA}}}{\text{SNR}_2^{\text{VA}}[\gamma]}} \right], \quad (5.5)$$

unde γ este vectorul care include toți indicii structurali ai modelului de identificare. El definește cromozomul în cadul AG, fiecare indice structural constituind o genă a acestuia. În definiția lui F , intervin următorii parametri:

- ponderile $\eta_1^{\text{ID}}, \eta_1^{\text{VA}}, \eta_2^{\text{ID}}, \eta_2^{\text{VA}}$ care se pot alege egale, dacă lungimea vectorului cu date de identificare este aceeași cu a vectorului cu date de validare; altfel, ele sunt proporționale cu lungimile seturilor de date aferente; în plus, suma lor este unitară;
- factorii de scalare, $\mu_1^{\text{ID}}, \mu_1^{\text{VA}}, \mu_2^{\text{ID}}, \mu_2^{\text{VA}}$, care pot fi aleși experimental, plecând de la valoarea unitară.

Fiecare dintre cele două canale de ieșire are propriul său cromozom. În urma utilizării metaeuristicii ar trebui să fie returnate ca rezultate:

- soluțiile optime pentru cei doi cromozomi;
- valoarea funcției de *fitness* pentru cea mai bună soluție.

Unui singur cromozom de canal $j \in \{1, 2\}$ îi corespund următoarele gene (folosind, de exemplu, ecuația (5.1)):

Indicii minori, cu o posibilă variație în intervalul (0,20):

- na_j - indicele corespunzător polinomului A (gradul polinomului) ;
- $na_j, \dots, na_{jP_{j,1}}$ - indicii corespunzători polinomului $A_{P_{j,1}}$;

Indicii minori, cu o posibilă variație în intervalul (0,100):

- $nb_{j,1}$ - indice corespunzător polinomului $B_{j,1}$;
- $nb_{j,1,1}, \dots, nb_{j,1,M_{j,1}}$ - indicii corespunzători polinomului $B_{m_{j,1}}$;
- $nb_{j,2}$ - indice corespunzător polinomului $B_{j,2}$;
- $nb_{j,2,1}, \dots, nb_{j,2,M_{j,2}}$ - indicii corespunzători polinomului $B_{m_{j,2}}$;
- $nd_{j,1,1}, \dots, nd_{j,1,K_{j,1}}$ - indicii corespunzători polinomului $D_{m_{j,1}}$;
- $nd_{j,2,1}, \dots, nd_{j,2,K_{j,2}}$ - indicii corespunzători polinomului $D_{m_{j,2}}$;
- $nc_{j,1}$ - indicele corespunzător polinomului C_j ;

Indicii majori, cu o posibilă variație în intervalul (0,10), valoarea nulă însemnând că neliniaritatea respectivă lipsește:

- $P_{j,1}, M_{j,1}, M_{j,2}, K_{j,1}, K_{j,2}$ - acești meta-indici reprezintă, de fapt, numerele de polinoame utilizate în ecuațiile (5.1) și (5.2).

Atunci când se decide utilizarea unui AG, prima etapă constă în stabilirea clară a elementelor cromozomului. Pentru a ușura maniera de implementare, am ales să lucrez cu un cromozom format din concatenarea celor doi sub-cromozomi de canal. Prin urmare, cromozomul γ este format din două seturi de indici structurali de forma celui prezentat în figura 5.4.

na_j	$nb_{j,1}$	$na_{j,1}$	\dots	$nb_{j,1,1}$	\dots	$nd_{j,1,1}$	\dots	$nb_{j,2}$	$nb_{j,2,1}$	\dots	$nd_{j,2,1}$	\dots	$nc_{j,1}$
--------	------------	------------	---------	--------------	---------	--------------	---------	------------	--------------	---------	--------------	---------	------------

Fig. 5.4. Structura cromozomului γ pentru modelul NARMAX

Întrucât funcția GA nu acceptă decât cromozomi de lungime fixă, indicii majori $P_{j,1}, M_{j,1}, M_{j,2}, K_{j,1}, K_{j,2}$ au fost aleși înainte de fiecare nouă rulare a AG, pentru a cunoaște întotdeauna numărul de elemente ale lui γ .

Etapa imediat următoare este definirea funcției cost, ținând cont de problema de optimizare ce trebuie rezolvată. În cazul modelului NARMAX, aceasta este funcția *fitness* definită în (5.5).

5.3.2. Calculul funcției *fitness* prin simularea modelului NARMAX

Funcția *fitness* definită în (5.5) poate fi evaluată numai dacă există o metodă de estimare a valorilor SNR din (5.4). Numărătorul din acele definiții este ușor de calculat,

Identificare neliniară pe bază de modele NARMAX

deoarece depinde numai de datele de ieșire măsurate. Însă, pentru a determina cele două dispersii ale erorilor de model, $\hat{\lambda}_1^2$ și $\hat{\lambda}_2^2$, este necesară obținerea ieșirilor simulate, cu ajutorul modelului NARMAX identificat, notate prin $y_{1,\text{sim}}$, respectiv $y_{2,\text{sim}}$. Odată aceste ieșiri determinate, erorile de model se calculează prin scăderea lor din ieșirile măsurate aferente:

$$\varepsilon_1[n] = y_1[n] - y_{1,\text{sim}}[n] \quad \& \quad \varepsilon_2[n] = y_2[n] - y_{2,\text{sim}}[n], \quad \forall n \in \mathbb{N}. \quad (5.6)$$

Dispersiile acestora se calculează, apoi cu formulele cunoscute:

$$\hat{\lambda}_1^2 = \frac{1}{N} \sum_{n=1}^N \varepsilon_1^2[n] \quad \& \quad \hat{\lambda}_2^2 = \frac{1}{N} \sum_{n=1}^N \varepsilon_2^2[n]. \quad (5.7)$$

Așadar, problema s-a redus la evaluarea ieșirilor simulate.

A. Separarea calculelor în simulare

Plecând de la ecuațiile modelului NARMAX (5.1) și (5.2), se poate aplica o împărțire a fiecareia cu polinoamele de stabilitate, A_1 , respectiv A_2 . Rezultă forma de exprimare prin filtre (pentru $\forall n \in \mathbb{N}$):

$$\begin{aligned} y_1[n] = & -\sum_{p=0}^{P_1-1} \frac{A_{1,p}(q^{-1})}{A_1(q^{-1})} y_1[n] y_1[n-p] + \\ & + \frac{B_{1,1}(q^{-1})}{A_1(q^{-1})} u_1[n] + \sum_{m=0}^{M_{1,1}-1} \frac{B_{1,1,m}(q^{-1})}{A_1(q^{-1})} u_1[n] u_1[n-m] + \sum_{k=0}^{K_{1,1}-1} \frac{D_{1,1,k}(q^{-1})}{A_1(q^{-1})} y_1[n] u_1[n-k] + \\ & + \frac{B_{1,2}(q^{-1})}{A_1(q^{-1})} u_2[n] + \sum_{m=0}^{M_{1,2}-1} \frac{B_{1,2,m}(q^{-1})}{A_1(q^{-1})} u_2[n] u_2[n-m] + \sum_{k=0}^{K_{1,2}-1} \frac{D_{1,2,k}(q^{-1})}{A_1(q^{-1})} y_1[n] u_2[n-k] + \frac{C_1(q^{-1})}{A_1(q^{-1})} e_1[n]; \end{aligned} \quad (5.8)$$

$$\begin{aligned} y_2[n] = & -\sum_{p=0}^{P_2-1} \frac{A_{2,p}(q^{-1})}{A_2(q^{-1})} y_2[n] y_2[n-p] + \\ & + \frac{B_{2,1}(q^{-1})}{A_2(q^{-1})} u_1[n] + \sum_{m=0}^{M_{2,1}-1} \frac{B_{2,1,m}(q^{-1})}{A_2(q^{-1})} u_1[n] u_1[n-m] + \sum_{k=0}^{K_{2,1}-1} \frac{D_{2,1,k}(q^{-1})}{A_2(q^{-1})} y_2[n] u_1[n-k] + \\ & + \frac{B_{2,2}(q^{-1})}{A_2(q^{-1})} u_2[n] + \sum_{m=0}^{M_{2,2}-1} \frac{B_{2,2,m}(q^{-1})}{A_2(q^{-1})} u_2[n] u_2[n-m] + \sum_{k=0}^{K_{2,2}-1} \frac{D_{2,2,k}(q^{-1})}{A_2(q^{-1})} y_2[n] u_2[n-k] + \frac{C_2(q^{-1})}{A_2(q^{-1})} e_2[n]. \end{aligned} \quad (5.9)$$

Folosind expresiile (5.8) și (5.9), se poate extrage separat semnalele de ieșire simulate utile, după cum urmează:

$$\begin{aligned}
 y_{1,u}[n] = & -\sum_{p=0}^{P_1-1} \frac{A_{1,p}(q^{-1})}{A_1(q^{-1})} y_{1,u}[n] y_{1,u}[n-p] + \\
 & + \frac{B_{1,1}(q^{-1})}{A_1(q^{-1})} u_1[n] + \sum_{m=0}^{M_{1,1}-1} \frac{B_{1,1,m}(q^{-1})}{A_1(q^{-1})} u_1[n] u_1[n-m] + \sum_{k=0}^{K_{1,1}-1} \frac{D_{1,1,k}(q^{-1})}{A_1(q^{-1})} y_{1,u}[n] u_{1,u}[n-k] + \\
 & + \frac{B_{1,2}(q^{-1})}{A_1(q^{-1})} u_2[n] + \sum_{m=0}^{M_{1,2}-1} \frac{B_{1,2,m}(q^{-1})}{A_1(q^{-1})} u_2[n] u_2[n-m] + \sum_{k=0}^{K_{1,2}-1} \frac{D_{1,2,k}(q^{-1})}{A_1(q^{-1})} y_{1,u}[n] u_2[n-k];
 \end{aligned} \tag{5.10}$$

$$\begin{aligned}
 y_{2,u}[n] = & -\sum_{p=0}^{P_2-1} \frac{A_{2,p}(q^{-1})}{A_2(q^{-1})} y_{2,u}[n] y_{2,u}[n-p] + \\
 & + \frac{B_{2,1}(q^{-1})}{A_2(q^{-1})} u_1[n] + \sum_{m=0}^{M_{2,1}-1} \frac{B_{2,1,m}(q^{-1})}{A_2(q^{-1})} u_1[n] u_1[n-m] + \sum_{k=0}^{K_{2,1}-1} \frac{D_{2,1,k}(q^{-1})}{A_2(q^{-1})} y_{2,u}[n] u_1[n-k] + \\
 & + \frac{B_{2,2}(q^{-1})}{A_2(q^{-1})} u_2[n] + \sum_{m=0}^{M_{2,2}-1} \frac{B_{2,2,m}(q^{-1})}{A_2(q^{-1})} u_2[n] u_2[n-m] + \sum_{k=0}^{K_{2,2}-1} \frac{D_{2,2,k}(q^{-1})}{A_2(q^{-1})} y_{2,u}[n] u_2[n-k].
 \end{aligned} \tag{5.11}$$

Ele se pot simula revenind la ecuațiile cu diferențe:

$$\begin{aligned}
 A_1(q^{-1}) y_{1,u}[n] = & -\sum_{p=0}^{P_1-1} A_{1,p}(q^{-1}) y_{1,u}[n] y_{1,u}[n-p] + \\
 & + B_{1,1}(q^{-1}) u_1[n] + \sum_{m=0}^{M_{1,1}-1} B_{1,1,m}(q^{-1}) u_1[n] u_1[n-m] + \sum_{k=0}^{K_{1,1}-1} D_{1,1,k}(q^{-1}) y_{1,u}[n] u_{1,u}[n-k] + \\
 & + B_{1,2}(q^{-1}) u_2[n] + \sum_{m=0}^{M_{1,2}-1} B_{1,2,m}(q^{-1}) u_2[n] u_2[n-m] + \sum_{k=0}^{K_{1,2}-1} D_{1,2,k}(q^{-1}) y_{1,u}[n] u_2[n-k];
 \end{aligned} \tag{5.12}$$

$$\begin{aligned}
 A_2(q^{-1}) y_{2,u}[n] = & -\sum_{p=0}^{P_2-1} A_{2,p}(q^{-1}) y_{2,u}[n] y_{2,u}[n-p] + \\
 & + B_{2,1}(q^{-1}) u_1[n] + \sum_{m=0}^{M_{2,1}-1} B_{2,1,m}(q^{-1}) u_1[n] u_1[n-m] + \sum_{k=0}^{K_{2,1}-1} D_{2,1,k}(q^{-1}) y_{2,u}[n] u_1[n-k] + \\
 & + B_{2,2}(q^{-1}) u_2[n] + \sum_{m=0}^{M_{2,2}-1} B_{2,2,m}(q^{-1}) u_2[n] u_2[n-m] + \sum_{k=0}^{K_{2,2}-1} D_{2,2,k}(q^{-1}) y_{2,u}[n] u_2[n-k].
 \end{aligned} \tag{5.13}$$

Pentru aceasta, din vectorii globali al regresorilor, se va extrage doar partea care nu depinde de zgomotul alb. În schimb, zgomotele colorate sunt:

$$v_1[n] = \frac{C_1(q^{-1})}{A_1(q^{-1})} e_1[n] \quad \& \quad v_2[n] = \frac{C_2(q^{-1})}{A_2(q^{-1})} e_2[n], \quad \forall n \in \mathbb{N}. \tag{5.14}$$

Ele ar trebui estimate folosind diferite strategii. O strategie (neunică) este cea care urmează.

B. Estimarea zgomotelor colorate

Din procedura MCMMMP-MP, rezultă o estimare optimală a zgomotului alb,

Identificare neliniară pe bază de modele NARMAX

obținută prin filtrări succesive, aşa cum relevă pasul 2 al Algoritmului 3.1. Prin urmare, pe fiecare canal în parte, există câte o estimare a zgomotului alb: \hat{e}_1 , respectiv \hat{e}_2 . Cu ele, se pot evalua două zgomite colorate:

$$\hat{v}_1[n] = \frac{C_1(q^{-1})}{A_1(q^{-1})} \hat{e}_1[n] \quad \& \quad \hat{v}_2[n] = \frac{C_2(q^{-1})}{A_2(q^{-1})} \hat{e}_2[n], \quad \forall n \in \mathbb{N}, \quad (5.15)$$

folosind filtrarea cu modelele ARMA optimale deja identificate.

Pe de altă parte, între datele achiziționate la ieșirile instalației și cele utile simulate, există diferențe, asimilate ca realizări ale zgomotului colorat:

$$v_{1,\text{sim}}[n] = y_1[n] - y_{1,u}[n] \quad \& \quad v_{2,\text{sim}}[n] = y_2[n] - y_{2,u}[n], \quad \forall n \in \mathbb{N}, \quad (5.16)$$

Dacă modelul identificat este de calitate, atunci zgomitele colorate estimate, (5.15), ar trebui să difere de cele realizate, (5.16), cel mult printr-o constantă de amplificare/atenuare pe fiecare canal. Mai precis, ideal ar fi să se verifice egalitățile:

$$v_{1,\text{sim}}[n] = \sigma_1 \hat{v}_1[n] \quad \& \quad v_{2,\text{sim}}[n] = \sigma_2 \hat{v}_2[n], \quad \forall n \in \mathbb{N}, \quad (5.17)$$

unde σ_1 și σ_2 sunt constante de ajustare. Cum egalitățile anterioare nu se pot verifica în practică, este necesară utilizarea MCMMP pentru a estima valorile optimale ale celor două constante de ajustare. Astfel, se pot rezolva următoarele probleme de optimizare pătratică:

$$\hat{\sigma}_1 = \arg \min_{\sigma_1 \in \mathbb{R}^*} \sum_{n=1}^N (v_{1,\text{sim}}[n] - \sigma_1 \hat{v}_1[n])^2 \quad \& \quad \hat{\sigma}_2 = \arg \min_{\sigma_2 \in \mathbb{R}^*} \sum_{n=1}^N (v_{2,\text{sim}}[n] - \sigma_2 \hat{v}_2[n])^2, \quad (5.18)$$

ceea ce conduce la soluțiile optimale:

$$\hat{\sigma}_1 = \frac{\sum_{n=1}^N v_{1,\text{sim}}[n] \hat{v}_1[n]}{\sum_{n=1}^N \hat{v}_1^2[n]} \quad \& \quad \hat{\sigma}_2 = \frac{\sum_{n=1}^N v_{2,\text{sim}}[n] \hat{v}_2[n]}{\sum_{n=1}^N \hat{v}_2^2[n]}. \quad (5.19)$$

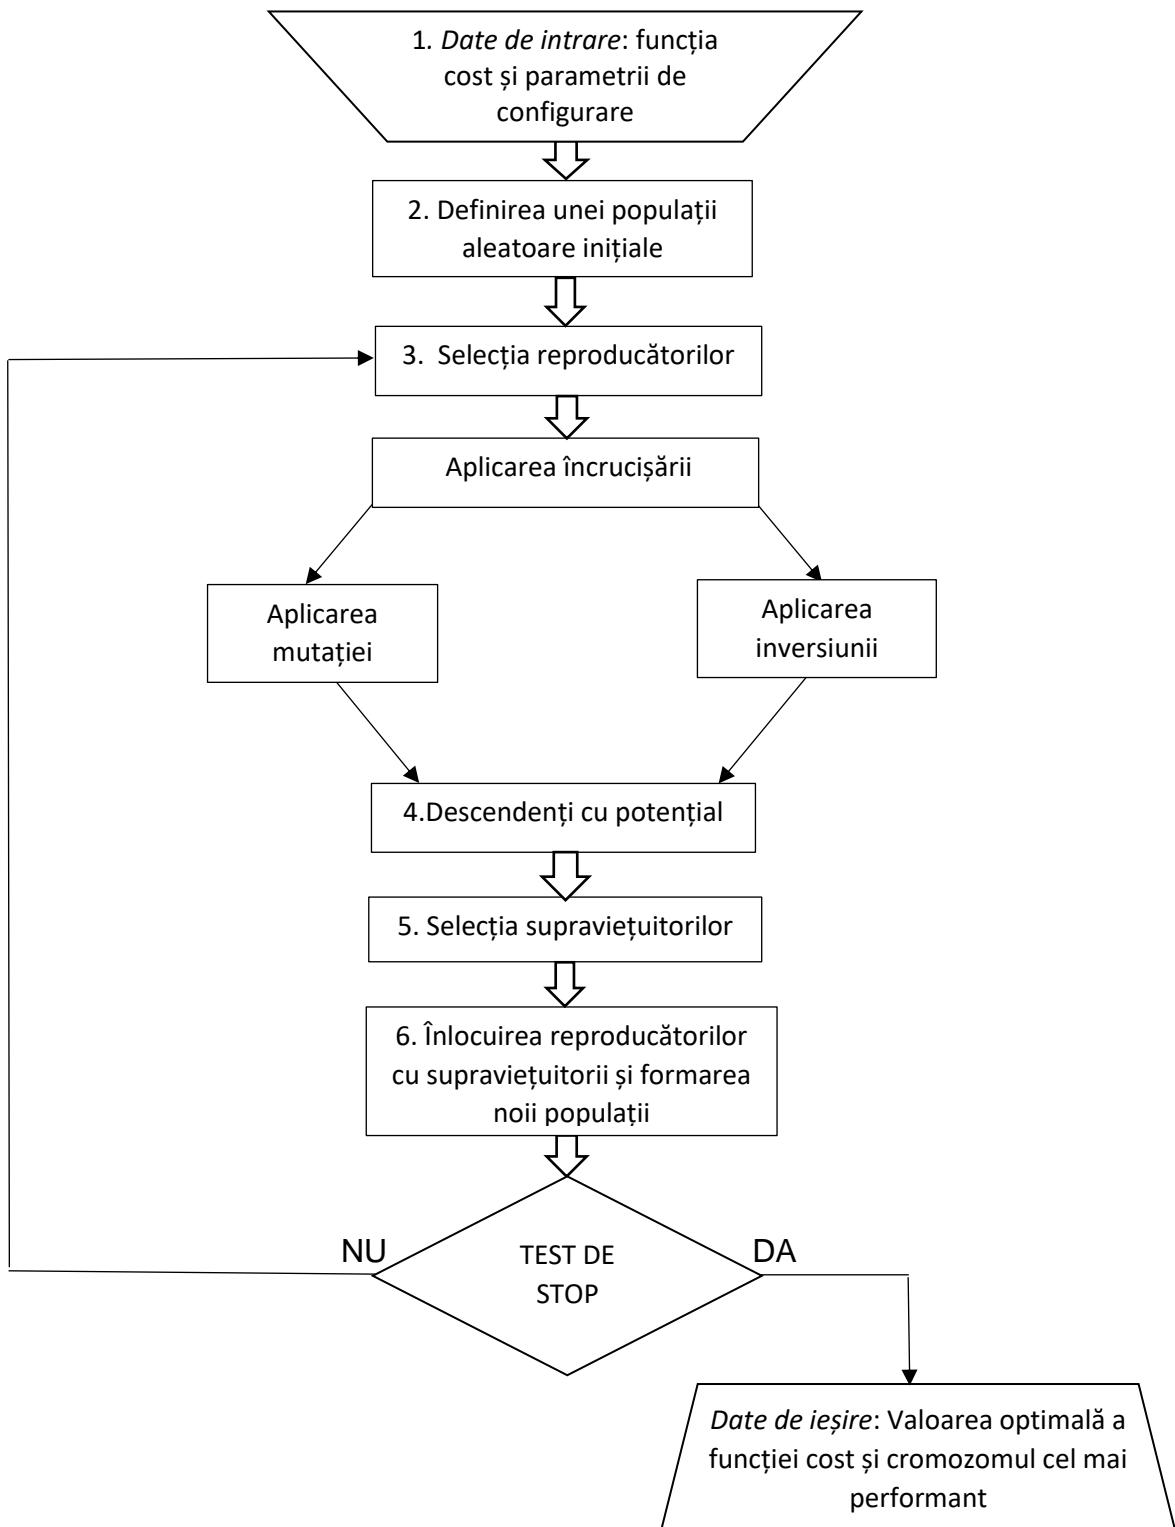
Prin urmare, valorile, teoretic, valorile simulate ale ieșirilor sunt:

$$y_{1,\text{sim}}[n] = y_{1,u}[n] + \hat{\sigma}_1 \hat{v}_1[n] \quad \& \quad y_{2,\text{sim}}[n] = y_{2,u}[n] + \hat{\sigma}_2 \hat{v}_2[n], \quad \forall n \in \mathbb{N}. \quad (5.20)$$

Cu toate acestea, deoarece zgomotul alb este estimat doar în faza de identificare, nu și în faza de validare, este de așteptat ca similitudinea dintre zgomitele colorate (5.15) și (5.16) să nu mai fie evidentă, ca în faza de identificare. De aceea, pentru faza de validare, constantele de ajustare σ_1 și σ_2 se vor forța la valori unitare.

5.3.3. Funcția GA din MATLAB

Pentru utilizarea într-un mediu de programare a unui AG, se poate utiliza diagrama logică din figura 4.1 [LUȚ2014], [ȘTE2014].

**Fig.5.5.** Schema logică a unui AG

Funcția GA din biblioteca de programare evoluționară a mediului MATLAB găsește minimul unei anumite funcții cost predefinite și a fost implementată pe baza diagramei logice din figura 5.5. Deși utilizarea funcției pare intuitivă, utilizatorul trebuie să înțeleagă semnificația parametrilor de intrare și modul de lucru cu aceștia. De asemenea, există mai multe feluri în care putem apela funcția, ținând cont de problema de optimizare pe care este necesar să o rezolvăm. Modul general de apelare ales este [MAT2022]:

Identificare neliniară pe bază de modele NARMAX

[soluție,Fitness] = ga (*fun*, *nvars*, *A*, *b*, *Aeq*, *beq*, *lb*, *ub*, *nonlcon*, *intcon*,*options*) .

Tabel 5.1. Semnificația parametrilor funcției GA din MATLAB

Argumente de intrare	Semnificații generale
<i>fun</i>	Numele funcției cost predefinite
<i>nvars</i>	Numărul variabilelor căutate (numărul de gene ale cromozomului)
<i>A și b</i>	Constrângeri de inegalitate liniare
<i>Aeq și beq</i>	Constrângeri de egalitate liniare
<i>lb</i>	Limitele inferioare de căutare ale variabilelor
<i>ub</i>	Limitele superioare de căutare ale variabilelor
<i>nonlcon</i>	Eventuale constrângeri neliniare
<i>intcon</i>	Constrângerea ca variabilele căutate să fie întregi (vector conținând pozițiile variabilelor constrânse)
<i>options</i>	Opțiuni pentru modificarea unor setări ale funcției

Notă. În caz de absență a unui argument de intrare, el va lua valorile implicate stabilite de către proiectantul rutinei [MAT2022].

Pentru a varia parametrii precum: numărul de iterații ale algoritmului, dimensiunea populației sau operațiile de selecție, încrucișare și mutație utilizate în mod implicit de către funcție, se poate modifica parametrul *options*.

Cele mai relevante opțiuni pe care le-am utilizat sunt enumerate în tabelul 5.2:

Tabel 5.2. Opțiuni de configurare ale funcției GA din MATLAB

Options	Explicație
'PopulationSize', <i>npop</i>	Dimensiunea dorită pentru populația de cromozomi care evoluează pentru găsirea soluției optimale.
'CreationFcn', @gacreationuniform	Funcție care generează populația inițială (de exemplu, uniform repartizată în spațiul de căutare).
'SelectionFcn', @selectionstochunif	Funcția de selecție a celor mai buni cromozomi.
'CrossoverFcn', @crossoverscattered	Funcția de încrucișare a reproducătorilor.
'MutationFcn', @mutationadaptfeasible	Funcția de mutație a descendenților.
'FunctionTolerance', <i>t</i>	Aici, <i>t</i> este un scalar pozitiv de ordinul 10^{-6} . Algoritmul se oprește dacă modificarea relativă medie a celei mai bune valori de funcție cost de-a lungul numărului de generații <i>x</i> al MaxStallGenerations este mai mică sau egală cu această toleranță. Aceasta este, practic, testul de stop.
'MaxStallGenerations', <i>x</i>	Numărul maxim de iterații după care se oprește algoritmul de căutare. Valoarea implicită este de $100 * nvars$.
'MaxGeneration', <i>y</i>	Optional, funcție care afisează grafic valorile găsite în timpul rulării algoritmului.
'PlotFcn', @gaplotbestf	Optional, funcție care afisează grafic valorile găsite în timpul rulării algoritmului.

Deoarece determinarea indicilor structurali a presupus determinarea celei mai mari valori a funcției *fitness* (5.5), a trebuit transformată problema de minimizare rezolvată în mod implicit de funcția GA în una de maximizare. Acest lucru de poate rezolva astfel:

$$\max(F) = -\min(-F) \quad (5.21)$$

De asemenea, un alt aspect care necesită atenție este transmiterea ca parametru rutina care implementează definiția (5.5) a funcției *fitness*. Este necesar ca AG să interpreteze clar cine este cromozomul. De aceea, parametrul *fun* din tabelul 5.1 are forma:

$$fun = @ (X) (-F)(X, params) . \quad (5.22)$$

În ecuația (5.22) *X* reprezintă, concret, cromozomul γ , iar *params* semnifică restul parametrilor de intrare ai funcției cost.

Pentru implementări în mediul MATLAB a AG, mai există și biblioteca GAOT, ce are incluse mai multe variante pentru funcțiile de selecție, mutație și încrucișare. Deși maniera de lucru ar fi asemănătoare cu cea prezentată în cadrul acestei subsecțiuni, funcția GA simplă reprezintă, de fapt, o versiune actualizată, mai convenabil de apelat pentru utilizatori.

Din perspectivă personală, punctul sensibil al utilizării unei metaeuristici este reprezentat de alegerea potrivită a parametrilor de configurare. Aceasta depinde de experiența utilizatorului, acumulată pe baza testelor și a analizei mai multor seturi de rezultate. Totuși, ideal ar fi ca algoritmul să fie configurat astfel încât să aibă un spațiu de căutare cât mai larg, limite superioare suficient de mari, un număr de generații cât mai mare și o dimensiune potrivită a populației. Astfel, cresc șansele obținerii unor soluții cât mai apropiate de optimul căutat.

6. Rezultate de simulare

6.1. Seturi de date achiziționate

Așa cum am menționat anterior în subsecțiunea 5.2.1, este necesară achiziția a câte două seturi de date corespunzătoare fiecărui canal de ieșire. Două seturi sunt alocate identificării modelului neliniar, în timp ce alte două sunt folosite în procesul de validare a modelului identificat anterior.

În conformitate cu informațiile din [CUL2015], în practică, datele de validare sunt generate prin stimularea instalației cu diferite tensiuni la intrare. Precum sugerează figura 6.1, cele două semnale pseudo-aleatoare de intrare U1 și U2 au fost generate în intervalul [5,10] V. Ele sunt folosite atât pentru a obține setul de date folosit în identificarea modelului NARMAX, cât și pentru achiziția datelor de validare. Pentru validare, cele două semnale au fost schimilate între ele: U1 s-a aplicat pe canalul 2 de intrare, iar U2 – pe canalul 1 de intrare. De asemenea, se poate observa că numărul eșantioanelor achiziționate este de 800 pe fiecare canal. Perioada de eșantionare a fost stabilită la 1 s.

Identificare neliniară pe bază de modele NARMAX

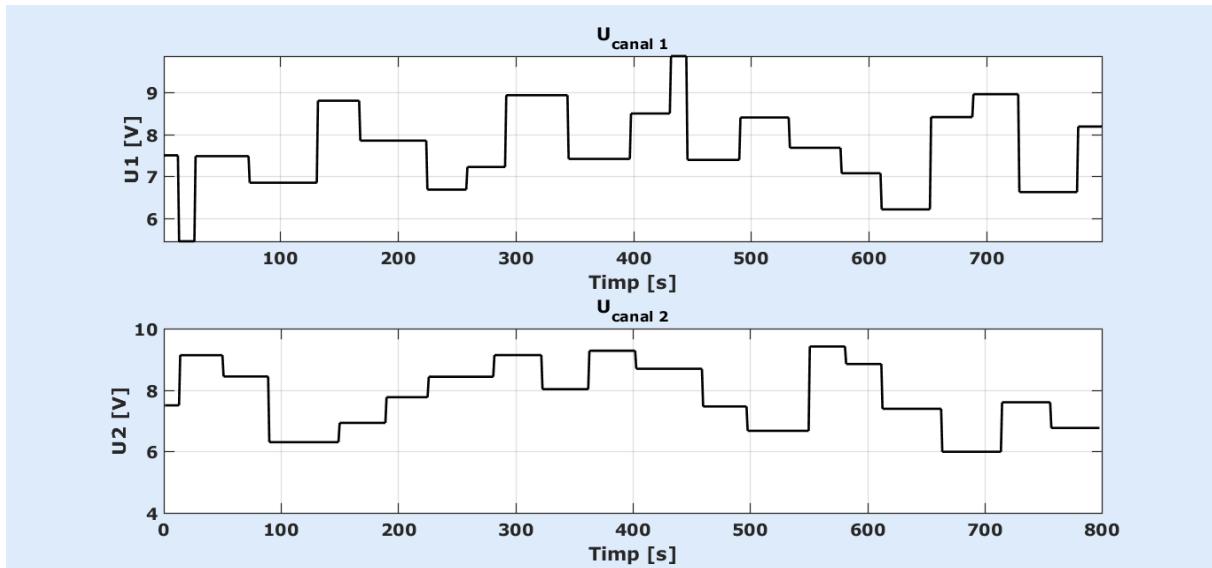


Fig. 6.1. Semnale de intrare utilizate pentru achiziția seturilor de date, pentru ambele canale de la instalația ASTANK2

În figura 6.2, sunt ilustrate ieșirile corespunzătoare stimulării instalației cu intrările U1 pe canalul 1 și U2 pe canalul 2.

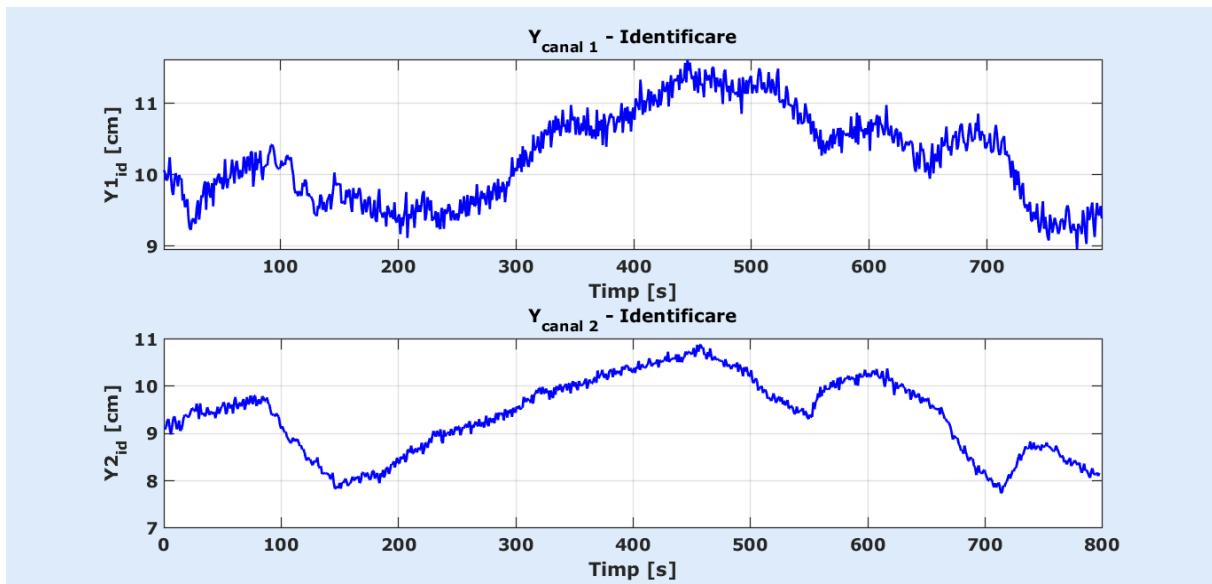


Fig. 6.2. Semnale de ieșire furnizate de cele două canale ale instalației ASTANK2, după stimularea cu intrările de identificare

În mod asemănător, figura 6.3 arată variații ale semnalelor de ieșire, după stimularea instalației cu intrările inter-schimbată (U1 pe canalul 2 și U2 pe canalul 1), acestea constituind datele de validare.

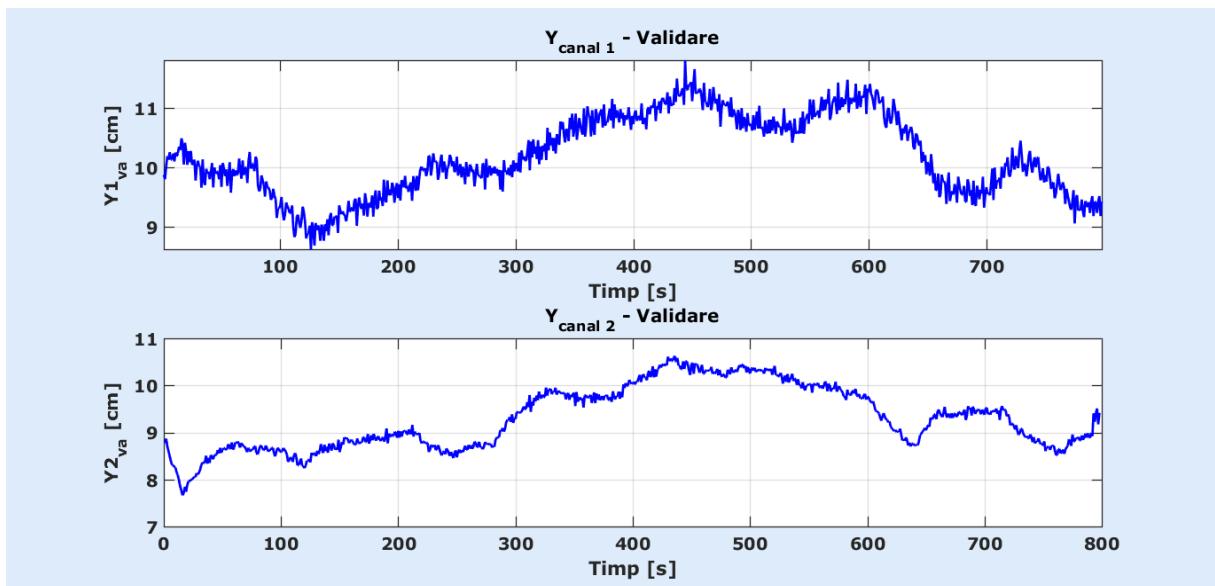


Fig 6.3. Semnale de ieșire furnizate de cele două canale ale instalației ASTANK2, după stimularea cu intrările de validare

Prima caracteristică evidentă a semnalelor este dată de faptul că acestea sunt afectate de zgomot. Pentru fiecare semnal măsurat va fi estimat modelul NARMAX prin aplicarea întregului proces de identificare. Zgomotele considerabile care afectează datele de ieșire sunt cauzate în principal de calitatea modestă a celor doi senzori de nivel (LT1 și LT2 în figura 5.1), când procesul de curgere este afectat de fenomenul turbulentelor. Acest fenomen apare ca urmare a schimbărilor brusă de debit, induse de salturile pe diferite trepte ale semnalelor din figura 6.1, când sunt aplicate asupra electrovalvelor FC1 și FC2 (figura 5.1).

6.2. Modelele optimale obținute

Pentru o analiză completă a rezultatelor de identificare și simulare am prevăzut două scenarii, și anume:

- Scenariul în care vectorul regresorilor corespunzător modelului (construit cu ajutorul ecuațiilor (2.7), (2.8), (5.1) și (5.2)) este format numai din date de intrare măsurate, fără a conține valori simulate/predictate. Aceasta presupune ca inițializarea să fie făcută numai cu date de ieșire disponibile. Se mai numește și *predicție cu un singur pas* sau mai simplu *uni-pas*.
- Scenariul în care vectorul regresorilor conține numai date de intrare măsurate, dar datele de ieșire sunt numai cele simulate. Inițializarea este realizată cu date de ieșire nule, acest tip de predicție numindu-se *predicție multi-pas*.

Înaintea simulărilor a fost necesară însă determinarea structurii optimale a modelului. Aceasta a presupus configurația potrivită a funcției GA în încercarea de a rezolva problema de optimizare folosind funcția *fitness* (5.5). Pentru aceasta, ponderile de la numărător au fost stabilite la valoarea 0.25 (având în vedere că datele de identificare și de validare au aceeași dimensiune), iar factorii de ajustare de la numitor au fost setați la valoarea 0.8 (care asigură o bună discriminare între modele cu performanțe apropriate). Parametrii de configurație au fost stabiliți după cum se arată în tabelul 6.2.

Tabel 6.2. Indicii structurali optimali determinați cu ajutorul funcției GA din MATLAB

Caz	Indicii optimali			Fitness
	Meta-indicii	Cromozom canal 1	Cromozom canal 2	
Predicție uni-pas	(1,2,1,2,1,2,1,2,1,2)	(1,2,1,1,4,2,2,2,3,5,3)	(1,2,1,1,2,3,3,1,5,3,5,3)	~86,56%
Mixt	(1,2,1,2,1,2,1,2,1,2)	(1,2,1,1,4,2,2,2,3,5,3)	(1,2,1,1,2,3,3,1,5,3,5,3)	~72,85%
Predicție multi-pas	(1,2,1,2,2,1,2,1,1,2)	(4,4,6,9,1,9,10,1,2,10,3,7)	(1,10,7,6,1,1,1,10,8,6,3)	~82,33%

Au fost testate o multitudine de soluții. Căutarea cu ajutorul unei metaeuristici este o procedură care are o durată proporțională cu numărul de variabile optimale ce necesită să fie determinate. Inițial, au fost lansate rulări cu un spațiu de căutare larg și un număr mare de iterări. Totuși, deoarece modelul este complex, având un număr de indici care poate varia destul de mult, rezultatele obținute cu indici structurali mult prea mari (indici majori superiori lui 3 și grade de polinoame mai mari ca 100) nu au fost pe măsura așteptărilor. Mai mult decât atât, timpul de rulare pentru astfel de teste este îndelungat (la nivel de zeci de ore de rulare), chiar dacă și probabilitatea de a găsi o soluție bună este mare.

Cele mai bune rezultate au fost obținute cu indici structurali minori având valori între 1 și 20, în timp ce indicii structurali majori au variat între 1 și 3. În tabelul 6.4, am expus cele mai bune soluții.

Pentru ca un model să fie considerat suficient de bun, ar trebui ca funcția *fitness* să nu ia valori mai mici de 75%, atât în cazul uni-pas, cât și în cel multi-pas (relativ la valorile ponderilor și factorilor de ajustare setate așa cum am precizat anterior).

Alegerea parametrilor de configurare pentru AG este departe de a fi subiectivă. Doar prin analiza diverselor soluții obținute cu configurații distincte ale algoritmului putem obține indicații privind direcția bună de căutare. Timpul de rulare este influențat direct atât de performanțele computerului pe care este lansat în execuție algoritmul, cât și de argumentele de intrare ale funcției GA, așa cum reiese din tabelul 6.3.

Tabel 6.3. Parametrii de configurare utilizați pentru AG, în determinarea modelelor de identificare optimale obținute

Caz	Parametru	Valoare	Indicii structurali majori	Computer	Timp de rulare
Predicție uni-pas	PopSize	30	(1,2,1,2,1,2,1,2,1,2)	ASUS VivoBook 14 – memorie RAM de 8GB la o frecvență de 2666 MHz, cu 6 nucle (2.3 GHz)	22 ore
	lb	1			
	ub	10			
	MaxGeneration	100*nvars			
Mixt	PopSize	30	(1,2,1,2,1,2,1,2,1,2)	Dell Latitude 3440 – memorie RAM de 4GB la o frecvență de 1600 MHz, cu 2 nucle (1.7 GHz)	-
	lb	1			
	ub	10			
	MaxGeneration	100*nvars			
Predicție multi-pas	PopSize	20	(1,2,1,2,2,1,2,1,1,2)	Dell Latitude 3440 – memorie RAM de 4GB la o frecvență de 1600 MHz, cu 2 nucle (1.7 GHz)	36 ore
	lb	1			
	ub	30			
	MaxGeneration	1000			

Parametrii prezentați în cadrul tabelului 6.2, care nu se regăsesc în tabelul specific de mai sus, au luat valorile lor implicate, alese de echipa de programatori a companiei MathWorks (de exemplu, „MaxStallGenerations” are o valoare implicită setată la 50, iar „FunctionTolerance” este setat convenabil ca fiind 10^{-6}).

6.3. Performanțele modelelor optimale

Modelele de identificare optimale au fost testate în cadrul a 3 scenarii:

1. **Scenariul UNI-PAS.** S-a determinat un model NARMAX optimal, folosind predicția uni-pas. Folosind acest model, s-a simulat funcționarea instalației ASTANK2 pe seturile de date de identificare și validare, tot în regim de predicție uni-pas. (Cu alte cuvinte, vectorii regresorilor conțin numai date măsurate la intrarea și ieșirea instalației, indiferent de valoarea predictată cu ajutorul lor).
2. **Scenariul MIXT.** S-a folosit tot modelul NARMAX optimal din scenariul precedent, dar, de această dată, s-a simulat funcționarea instalației ASTANK2 în regim de predicție multi-pas. (Acum, vectorii regresorilor conțin date măsurate la intrare și date predictate anterior la ieșire, plecând de la o inițializare nulă).
3. **Scenariul MULTI-PAS.** S-a determinat un alt model NARMAX optimal, folosind predicția multi-pas. Cu acest model, s-a simulat funcționarea instalației ASTANK2 în regim de predicție multi-pas. (A fost eliminată complet abordarea uni-pas).

Există o motivație pentru alegerea acestor 3 scenarii. În mod normal, primul scenariu (care, aşa cum se va vedea, relevă cea mai bună performanță de simulare), ar trebui selectat pentru a demonstra că modelul identificat este optimal. Însă, acest model este inutilizabil în cazul integrării sale într-o aplicație de control automat, din cauză că nu se pot cunoaște a priori ieșirile sale, fără a trece printr-o simulare completă, folosind intrările prescrise. Or, aceste intrări nu pot fi cunoscute dinainte, deoarece ele sunt generate de către regulatorul automat utilizat, în timpul funcționării sistemului în buclă închisă. Pentru ca modelul de identificare să poată fi exploatat, este nevoie ca el să poată face față predicției multi-pas. Prin urmare, în scenariul al doilea, s-a conservat modelul optimal uni-pas, dar el a fost inițiat să ofere predicții multi-pas ale ieșirilor. Pentru că, aşa cum se va vedea din graficele ce urmează, performanța modelului a fost sensibil degradată, s-a ajuns la scenariul al treilea. De această dată, datele de ieșire achiziționate au fost folosite exclusiv în determinarea modelului optimal cu ajutorul MCMM-MP și au mai intervenit doar pentru a putea evalua dispersiile erorilor de model, nu și în cursul simulării. Acest tip de model, deși are o performanță ușor inferioară celui uni-pas, este, totuși, cel dorit în aplicațiile de control, deoarece el poate fi integrat într-o schemă care funcționează în timp real (fără a cunoaște dinainte ce ieșiri se vor obține, pentru anumite intrări).

Figurile următoare au fost organizate în două categorii: una care se referă la performanțele modelului uni-pas în primele două scenarii și alta care prezintă performanța modelului multi-pas, în cadrul celui de-al treilea scenariu. Graficele din prima categorie sunt organizate pe două coloane: cea din stânga relevă performanța modelului uni-pas în scenariul UNI-PAS, iar cea din dreapta – performanța modelului uni-pas în scenariul MIXT.

În figura 6.4, au fost trasate, comparativ, semnalele de ieșire măsurate versus utile simulate, pe canalul 1, în cadrul orizontului de identificare. Încă de la aceste prime grafice, se poate constata că modelul uni-pas funcționează defectuos în scenariul MIXT, semnalul util fiind destul de depărtat de cel achiziționat, față de scenariul

Identificare neliniară pe bază de modele NARMAX

UNI-PAS. Aceasta atrage, după sine, obținerea unui colorat zgromot estimat mai bun în primul scenariu, față de al doilea, aşa cum ilustrează figura 6.6. Înaintea acestei figuri, în figura 6.5, este afișată grafic variația zgromotului alb estimat, rezultat în urma aplicării MCMMMP. Se poate observa că acest semnal este într-adevar apropiat de un zgromot alb ideal, deoarece nu se pot pune în evidență, cu ușurință, corelațiile dintre eșantioanele sale.

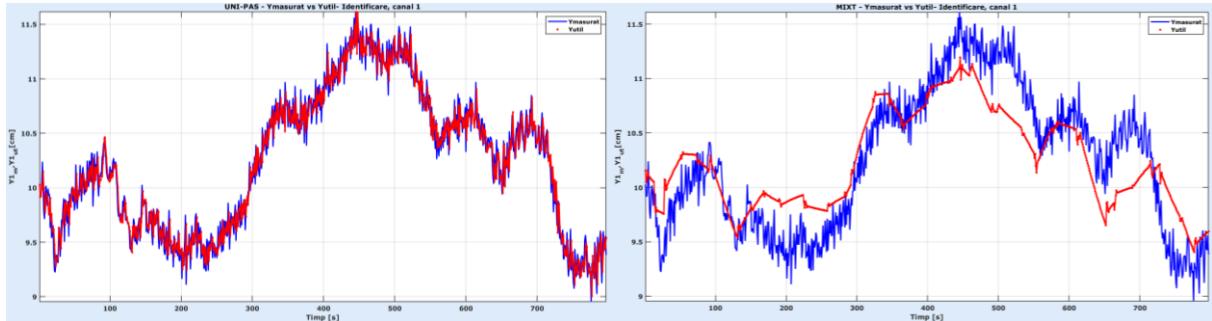


Fig. 6.4. Semnale de ieșire măsurate versus utile simulate pe canalul 1 de ieșire, orizontul de identificare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

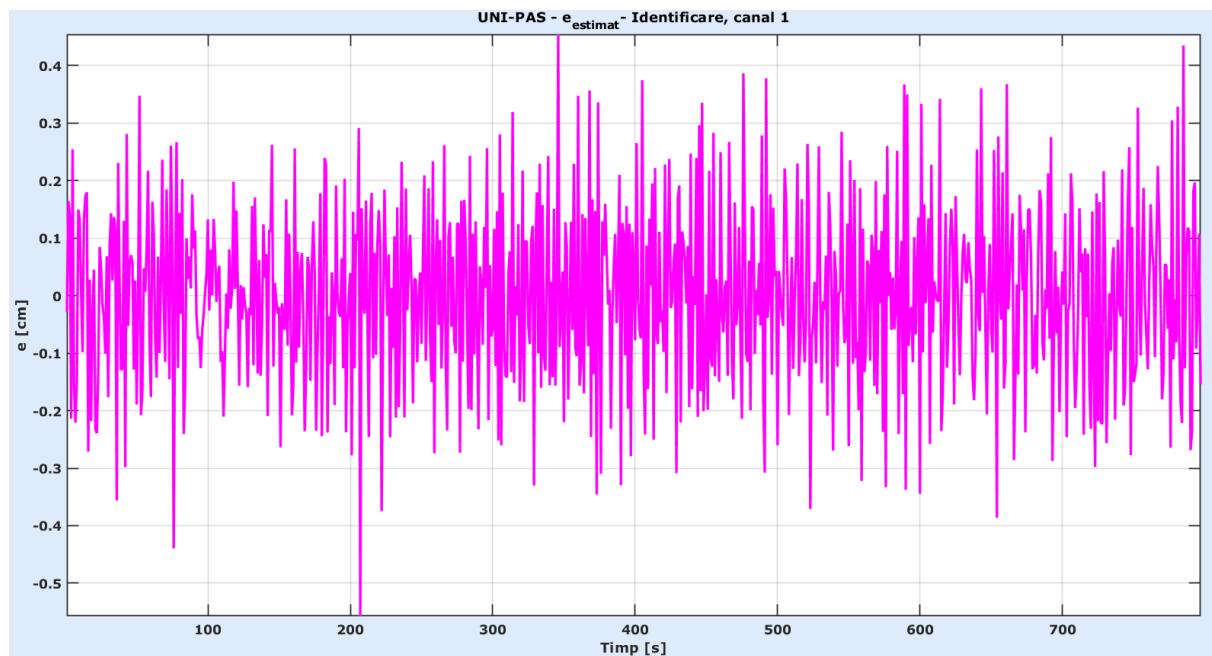


Fig. 6.5. Zgomotul alb estimat în cadrul procedurii numerice aferente MCMMMP-MP, pe canalul 1 de ieșire, orizontul de identificare (același pentru ambele scenarii, UNI-PAS și MIXT)

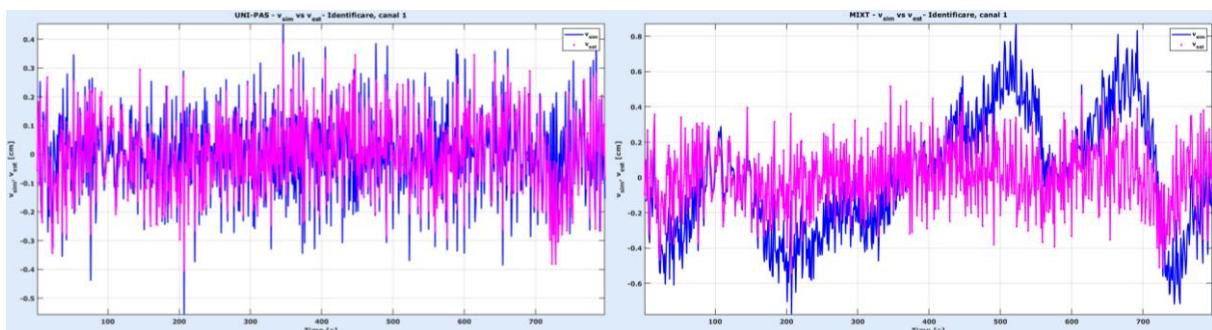


Fig. 6.6. Zgomotele colorate simulate versus estimate pe canalul 1 de ieșire, orizontul de identificare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

Adăugând zgomotul colorat estimat la ieșirea utilă, se obține semnalul simulație integral pe canalul 1 și orizontul de identificare. Variația sa este trasată în figura 6.7, prin comparație cu cea a datelor de ieșire aferente măsurate. Evident, în scenariul UNI-PAS, datele simulate se mulează foarte bine pe datele măsurate, fapt care a condus la o valoare destul de mare a funcției *fitness*. În scenariul MIXT, însă, se observă o diferență importantă între aceste două semnale, ceea ce a condus la micșorarea valorilor funcției *fitness*.

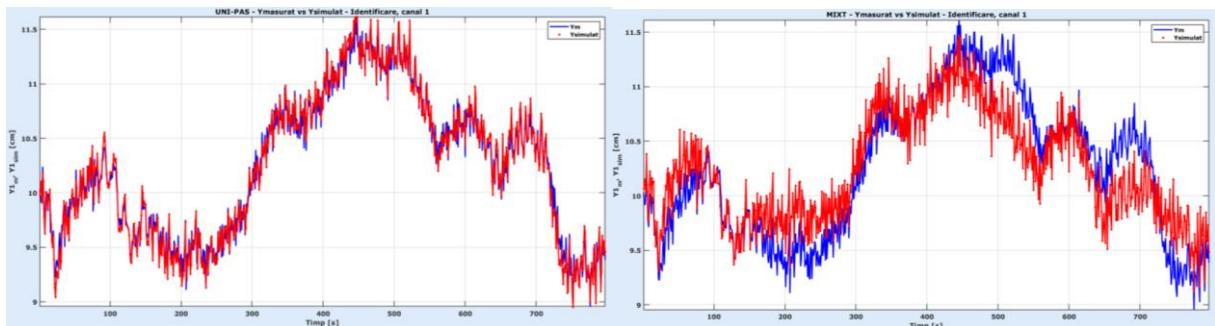


Fig. 6.7. Semnale de ieșire măsurate versus integral simulație pe canalul 1 de ieșire, orizontul de identificare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

Ultima comparație efectuată între cele două scenarii, pe canalul 1 de ieșire și orizontul de identificare este cea între erorile de model. Dacă modelul de identificare se apropie în simulație de comportamentul procesului real, atunci această eroare de model este similară unui zgomot alb. Altfel, ea prezintă caracteristicile unui zgomot colorat. Cu cât această eroare este mai departe de zgomotul alb, cu atât modelul este mai departe de proces. În figura 6.8, se poate observa că modelul uni-pas destul de apropiat de proces, în scenariul UNI-PAS (deși eroarea prezintă unele corelații între eșantioane), dar destul de departe de acesta, în scenariul MIXT. Eroarea de model din scenariul MIXT are corelații vizibile între eșantioane, ceea ce înseamnă că modelul NARMAX, deși optimal, nu este capabil să extragă o parte importantă din informația utilă a procesului. Această observație subiectivă este confirmată de valorile corespunzătoare ale dispersiilor, afișate pe grafice (peste 10 ori mai mici în scenariul UNI-PAS față de scenariul MIXT).

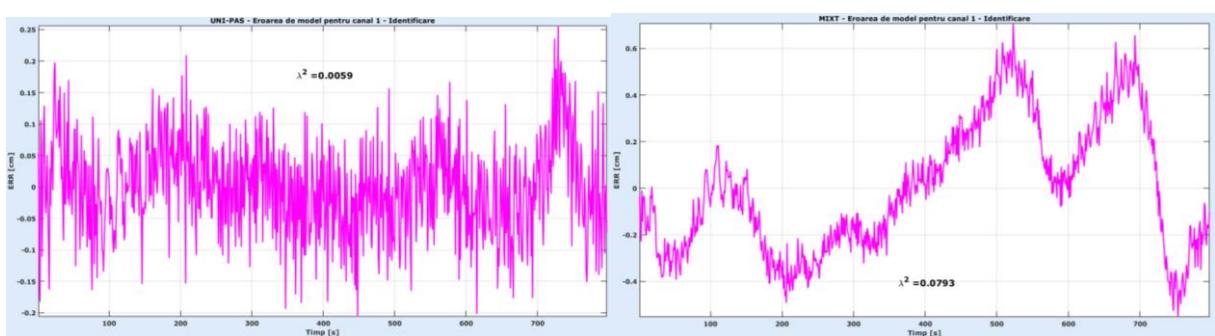


Fig. 6.8. Erori de model pe canalul 1 de ieșire, orizontul de identificare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

În continuare, sunt prezentate graficele aferente canalului 2 de ieșire, conservând orizontul de identificare. Aceste variații se pot vedea în figurile 6.9–6.13. Observațiile din cazul canalului de ieșire sunt valabile și în cazul canalului 2.

Apoi, s-a trecut la orizontul de validare, unde se pot analiza figurile 6.14–6.17 în cazul canalului 1 de ieșire și figurile 6.18–6.21 în cazul canalului 2 de ieșire. Este de așteptat ca modelul uni-pas să își degradeze performanța în cazul acestui orizont, deoarece datele de validare nu au fost utilizate în identificarea modelului. Ele au

Identificare neliniară pe bază de modele NARMAX

intervenit, totuși, în determinarea indicilor structurali optimali ai acestuia. În plus, zgometul alb estimat folosind MCMMMP-MP nu este estimat încă o dată pentru datele de validare; el rămâne același ca pe orizontul de identificare (adică estimările din figurile 6.5 și 6.10 sunt folosite și în cazul datelor de validare). Prin urmare, modelul uni-pas funcționează cu atât mai defectuos în scenariul mixt pe orizontul de validare, aşa cum ilustrează figurile menționate.

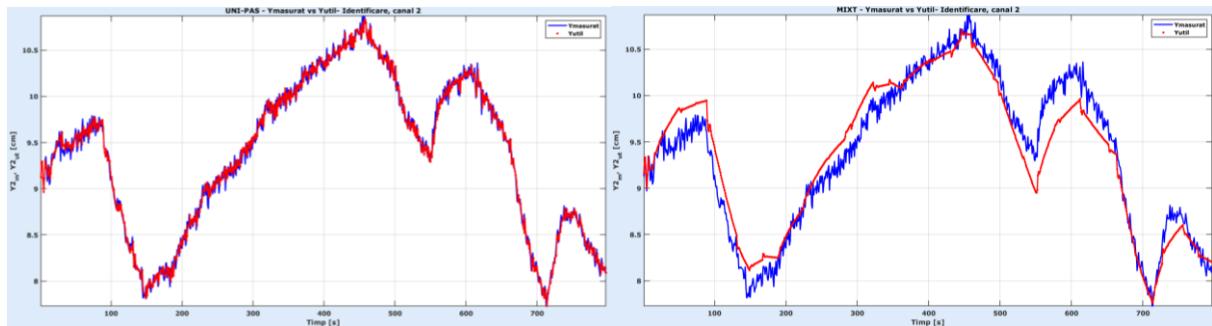


Fig. 6.9. Semnale de ieșire măsurate versus utile simulate pe canalul 2 de ieșire, orizontul de identificare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

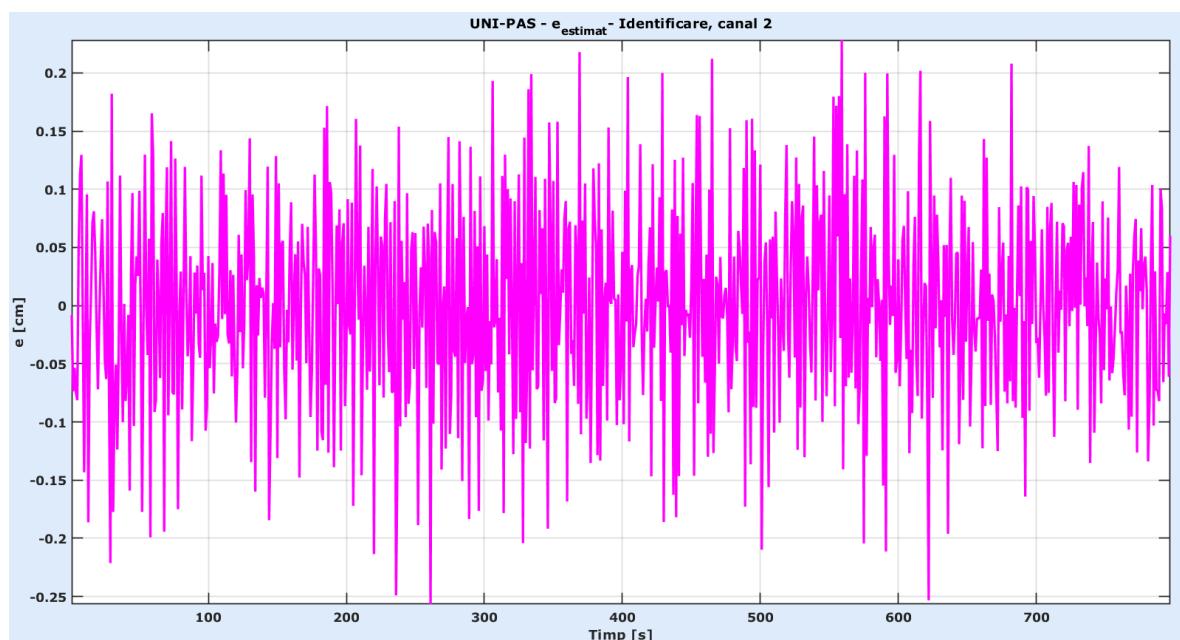


Fig. 6.10. Zgomotul alb estimat în cadrul procedurii numerice aferente MCMMMP-MP, pe canalul 2 de ieșire, orizontul de identificare (același pentru ambele scenarii, UNI-PAS și MIXT)

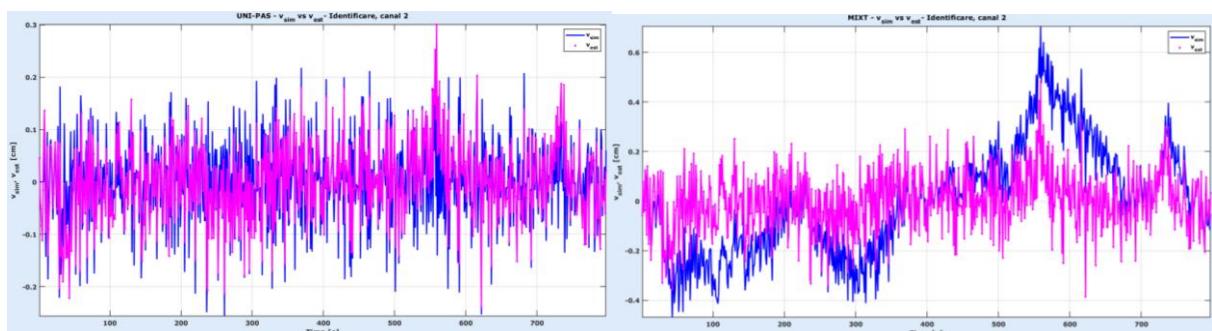


Fig. 6.11. Zgomotele colorate simulate versus estimate pe canalul 2 de ieșire, orizontul de identificare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

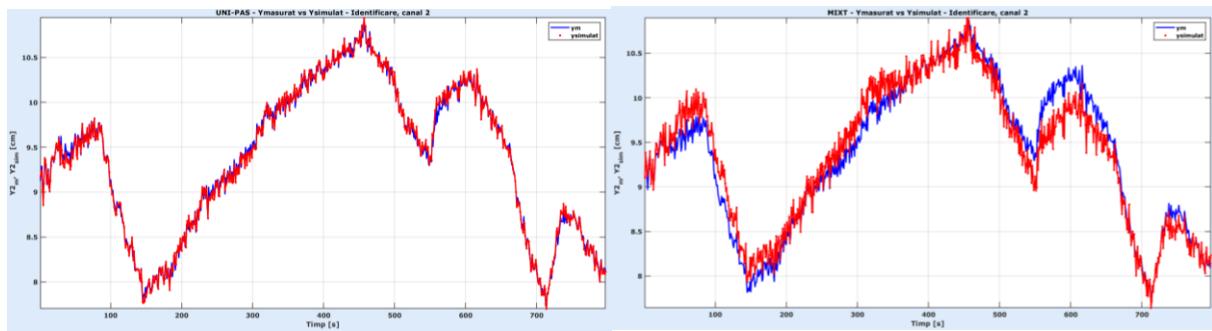


Fig. 6.12. Semnale de ieșire măsurate versus integral simulate pe canalul 2 de ieșire, orizontul de identificare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

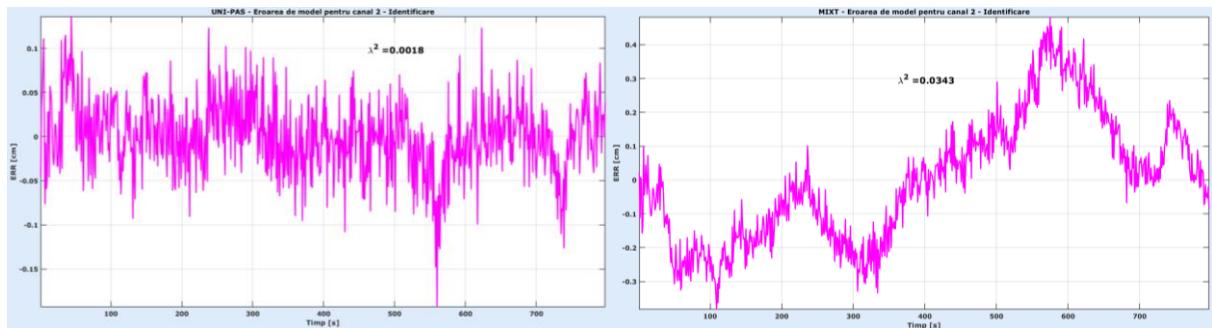


Fig. 6.13. Erori de model pe canalul 2 de ieșire, orizontul de identificare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

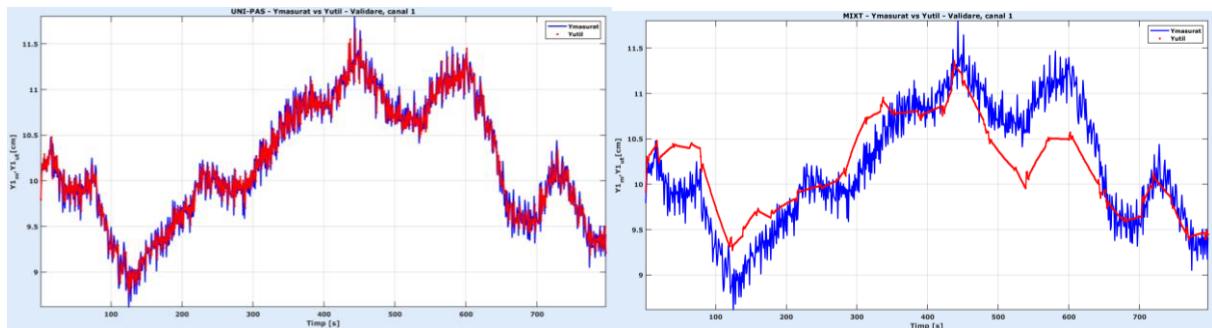


Fig. 6.14. Semnale de ieșire măsurate versus utile simulate pe canalul 1 de ieșire, orizontul de validare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

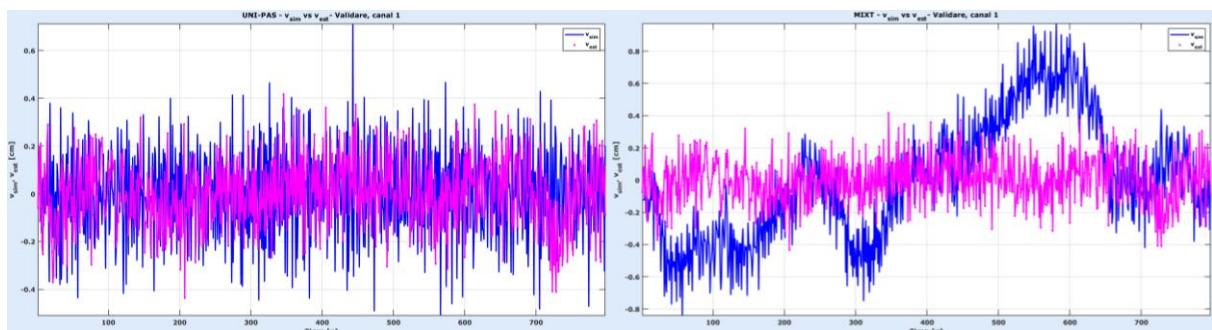


Fig. 6.15. Zgomotele colorate simulate versus estimate pe canalul 1 de ieșire, orizontul de validare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

Identificare neliniară pe bază de modele NARMAX

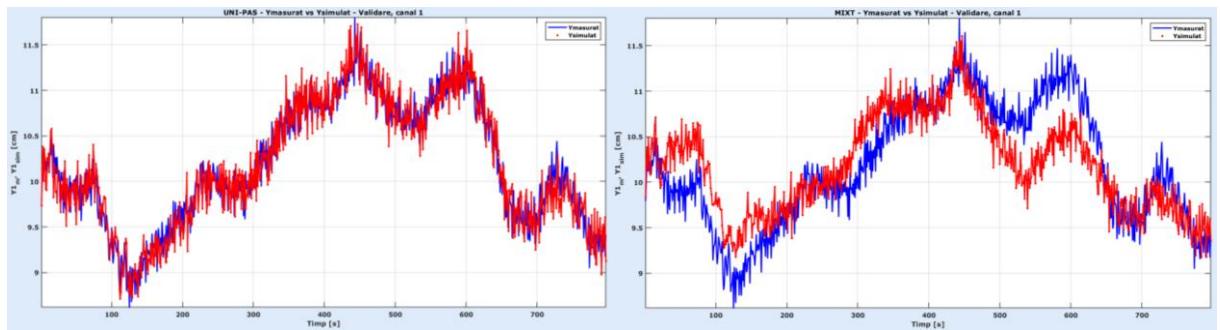


Fig. 6.16. Semnale de ieșire măsurate versus integral simulate pe canalul 1 de ieșire, orizontul de validare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

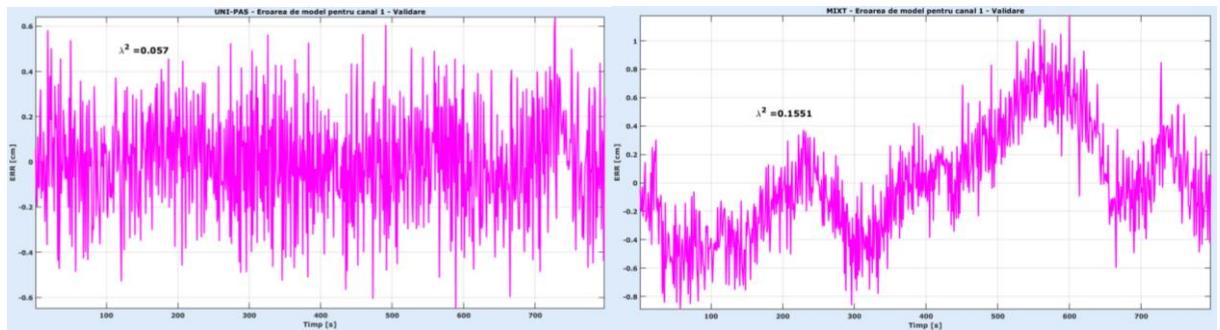


Fig. 6.17. Erori de model pe canalul 1 de ieșire, orizontul de validare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

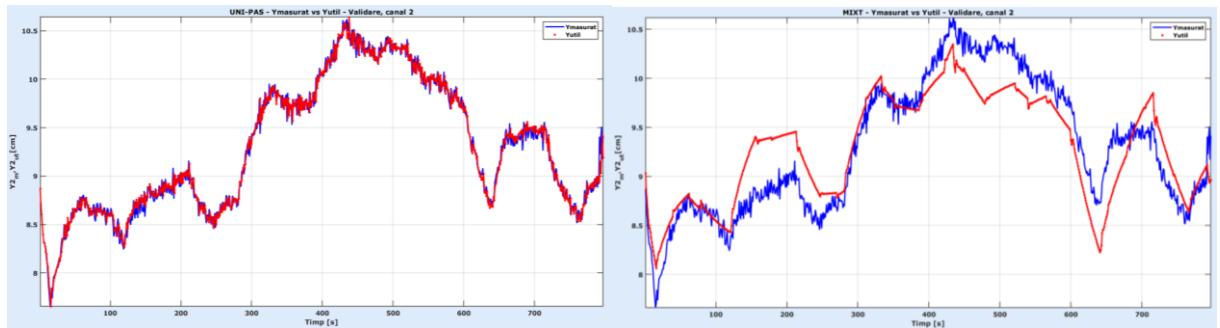


Fig. 6.18. Semnale de ieșire măsurate versus utile simulate pe canalul 2 de ieșire, orizontul de validare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

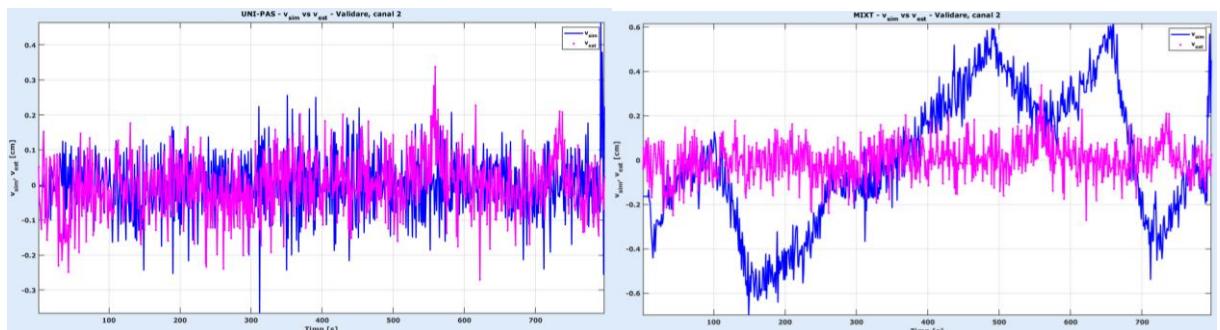


Fig. 6.19. Zgomotele colorate simulate versus estimate pe canalul 2 de ieșire, orizontul de validare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

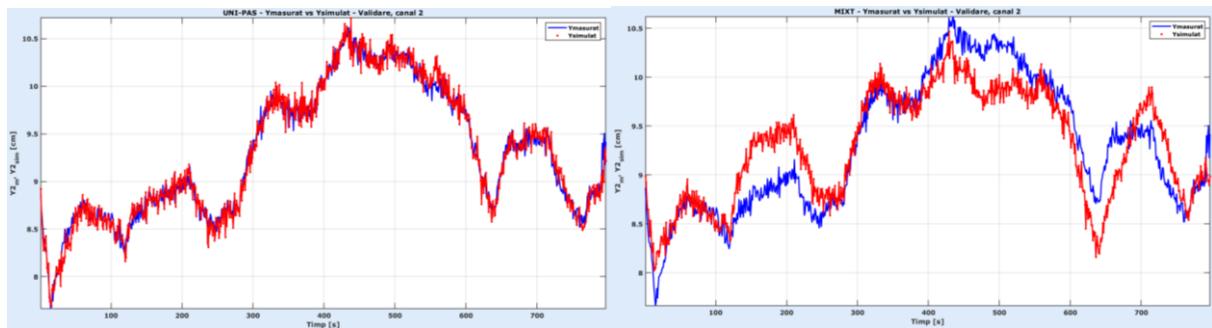


Fig. 6.20. Semnale de ieșire măsurate versus integral simulate pe canalul 2 de ieșire, orizontul de validare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

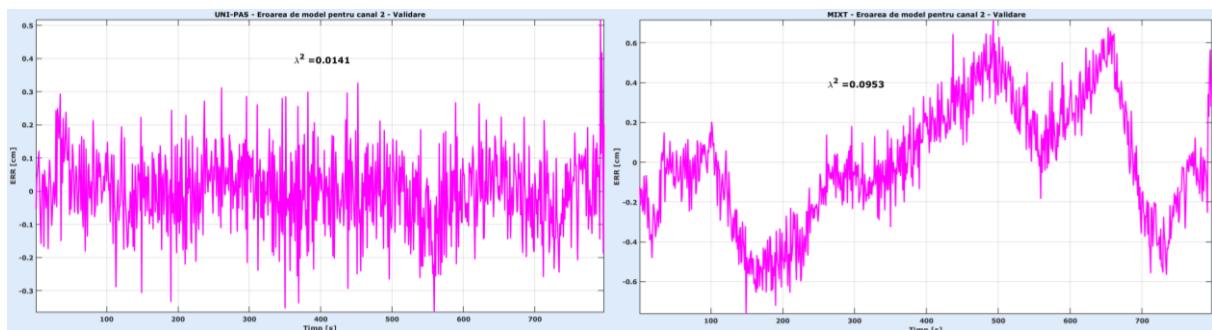


Fig. 6.21. Erori de model pe canalul 2 de ieșire, orizontul de validare (scenariul UNI-PAS în stânga, scenariul MIXT în dreapta)

Figurile 6.22–6.39 relevă performanța modelului NARMAX optimal de tip multi-pas, în scenariul multi-pas. Structura acestor grafice este aceeași ca în cazul scenariilor precedente. De această dată, se poate observa că modelul se adaptează destul de bine celor două orizonturi de date (dar ușor mai slab decât modelul uni-pas în scenariul UNI-PAS – a se vedea erorile de model din figurile 6.26, 6.31, 6.35 și 6.39), deși în cursul simularilor, nu se folosesc deloc datele de ieșire simulate. Modelul ar mai putea fi îmbunătățit printr-o identificare separată, cu ajutorul modelelor ARMA, a celor două erori de model din figurile 6.26 și 6.31. Este evident că ele au aspect de zgomote colorate. În urma acestei noi identificări zgomotul alb ce afectează măsurările poate fi mai bine estimat, pe fiecare canal în parte.

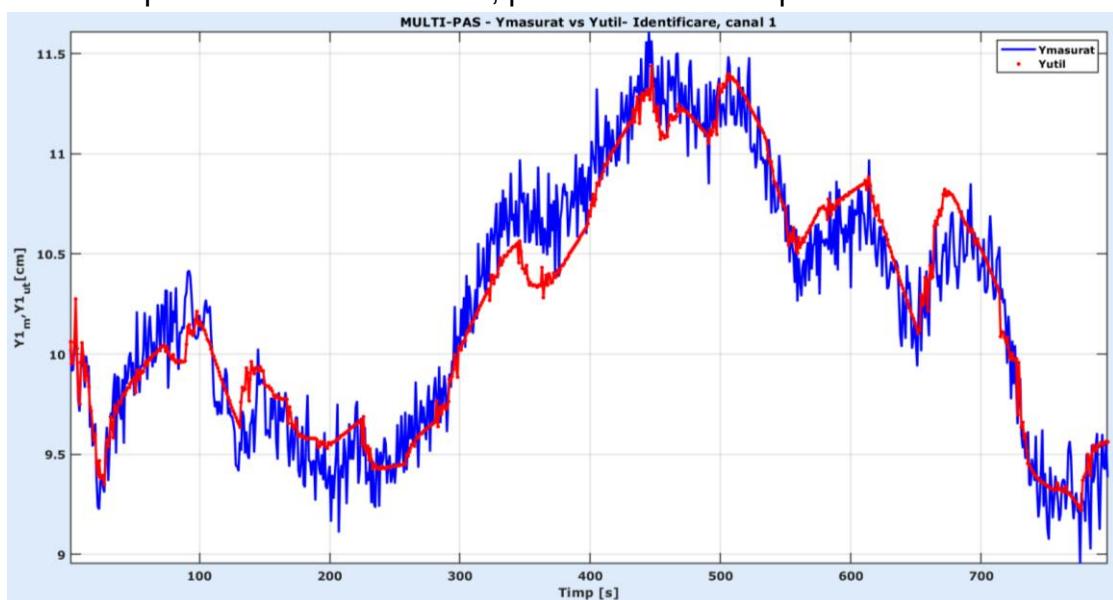


Fig. 6.22. Semnalul de ieșire măsurat versus util simulat pe canalul 1 de ieșire, orizontul de identificare (scenariul MULTI-PAS)

Identificare neliniară pe bază de modele NARMAX

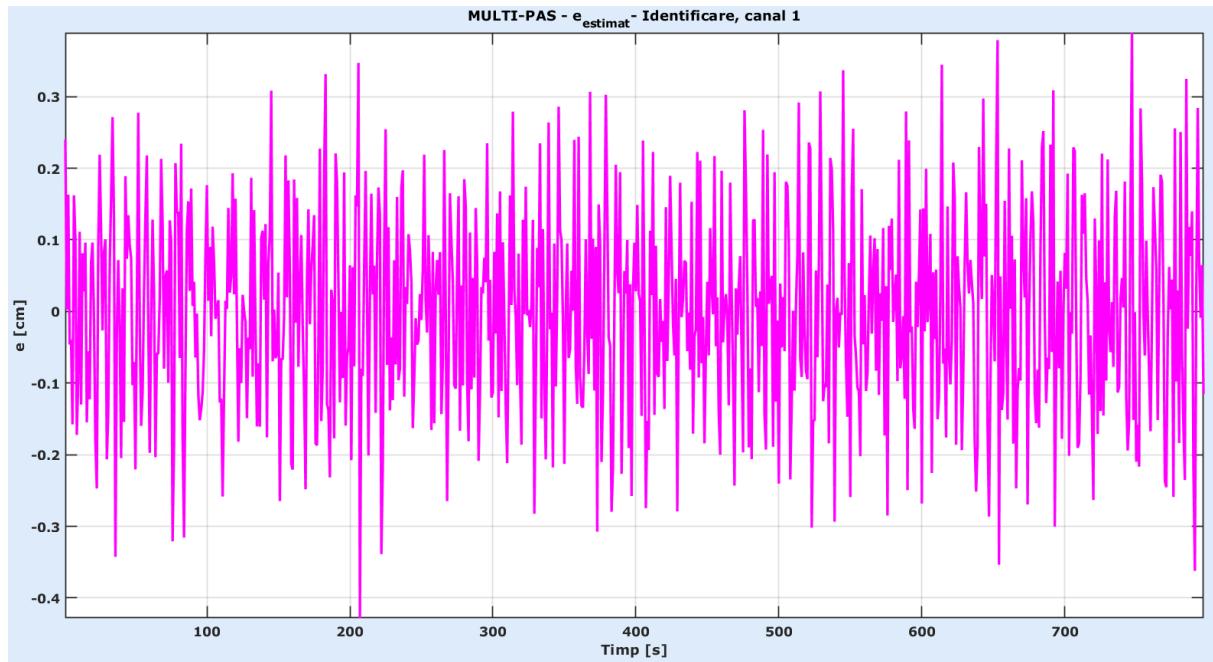


Fig. 6.23. Zgomotul alb estimat în cadrul procedurii numerice aferente MCMM-MP, pe canalul 1 de ieșire, orizontul de identificare (scenariul MULTI-PAS)

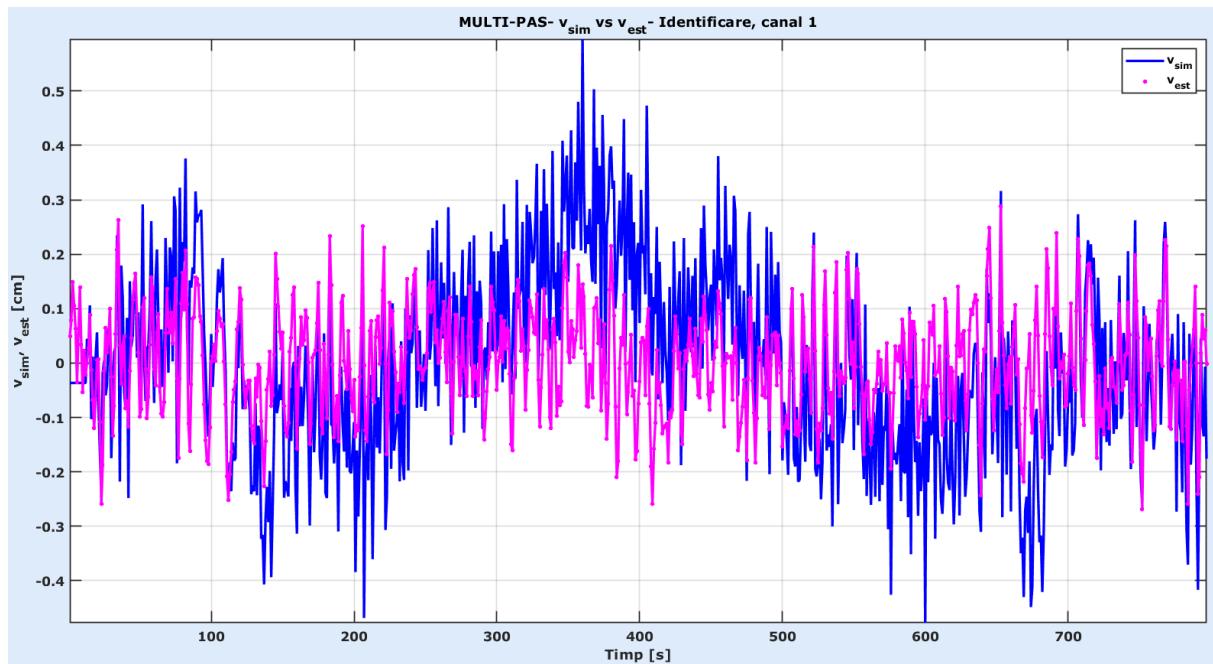


Fig. 6.24. Zgomotul colorat simulat versus estimat pe canalul 1 de ieșire, orizontul de identificare (scenariul MULTI-PAS)

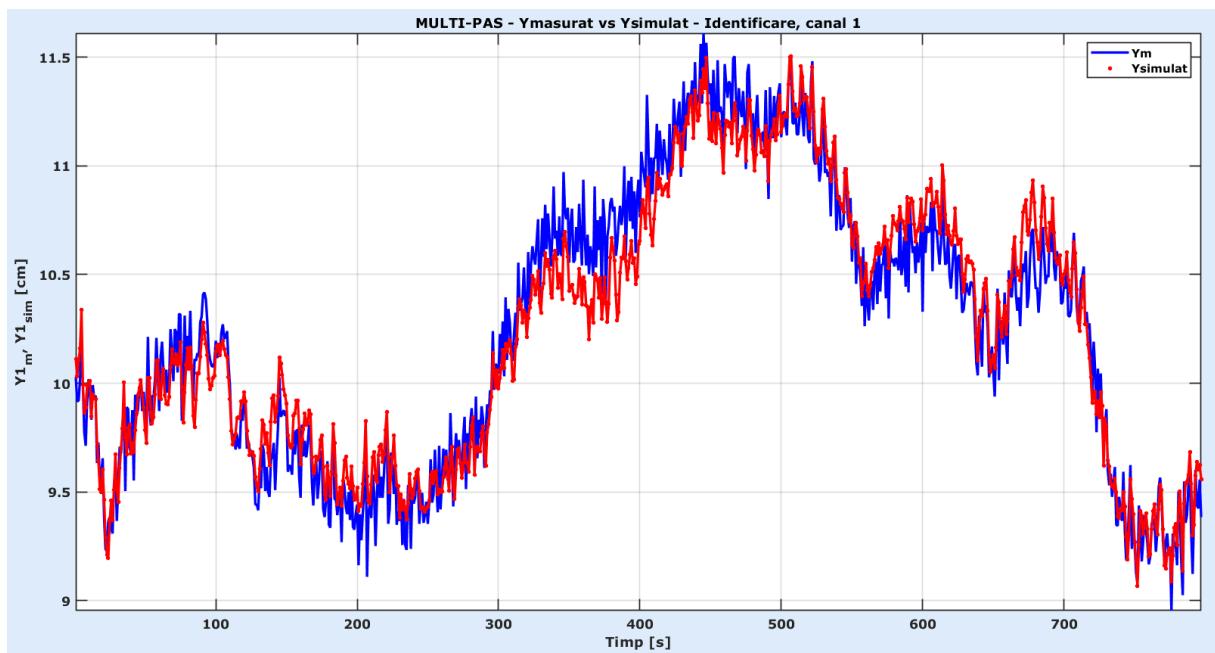


Fig. 6.25. Semnalul de ieșire măsurat versus integral simulat pe canalul 1 de ieșire, orizontul de identificare (scenariul MULTI-PAS)

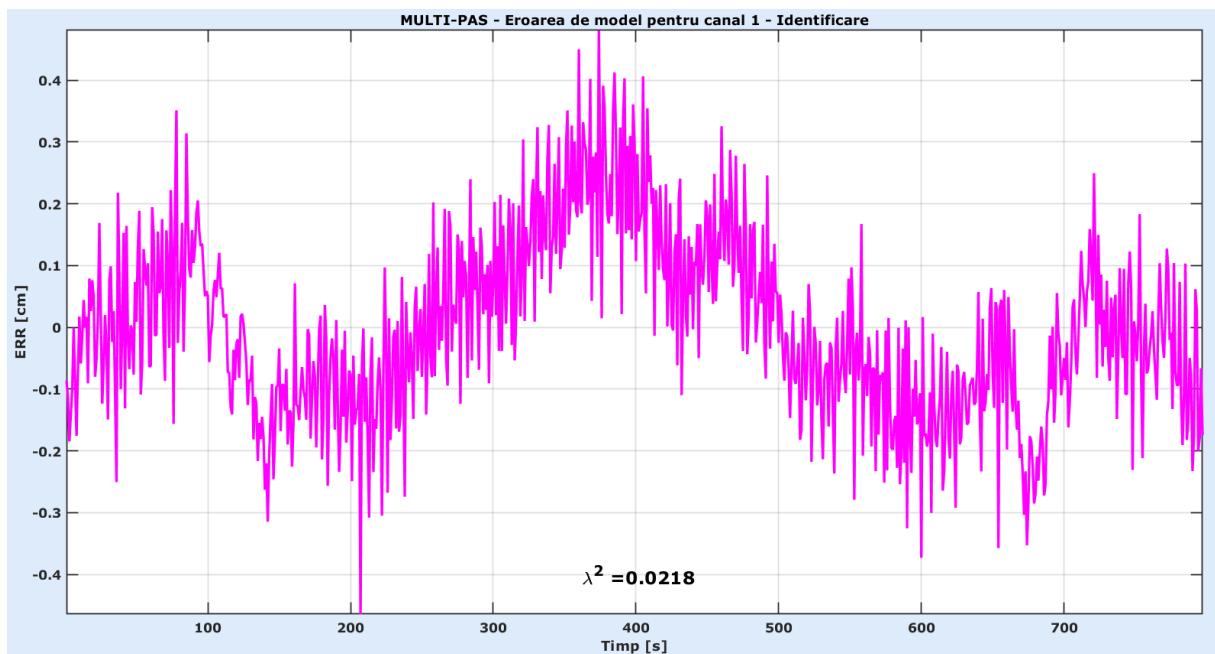


Fig. 6.26. Eroarea de model pe canalul 1 de ieșire, orizontul de identificare (scenariul MULTI-PAS)

Identificare neliniară pe bază de modele NARMAX

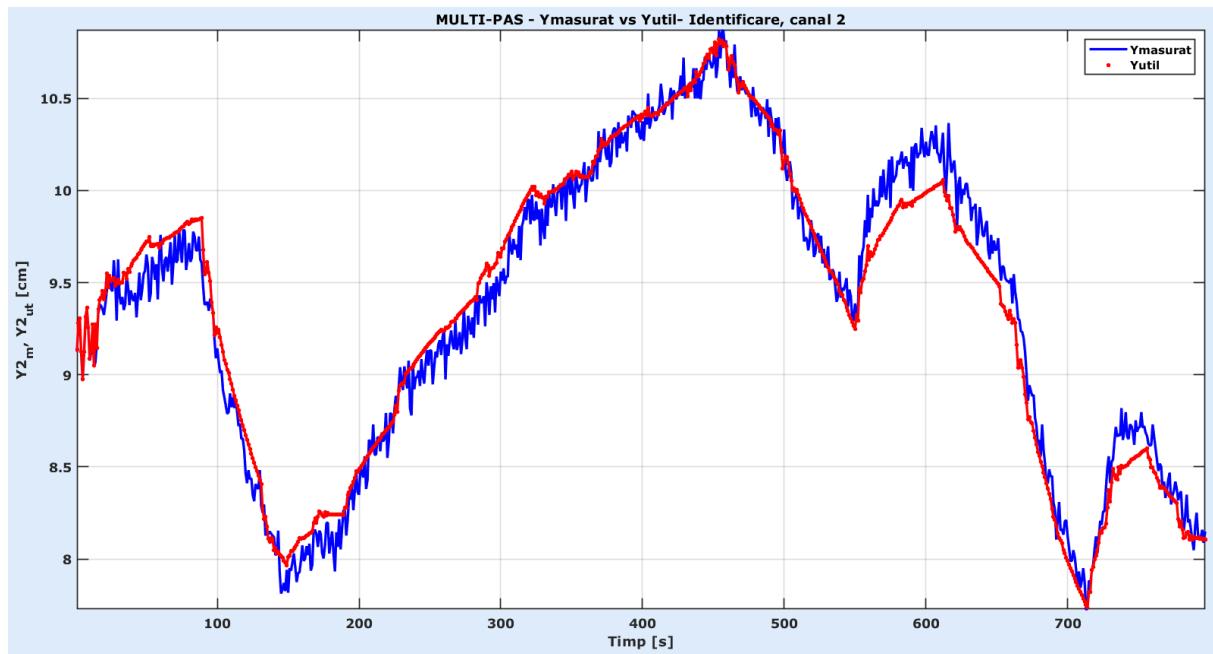


Fig. 6.27. Semnalul de ieșire măsurat versus util simulant pe canalul 2 de ieșire, orizontul de identificare (scenariul MULTI-PAS)

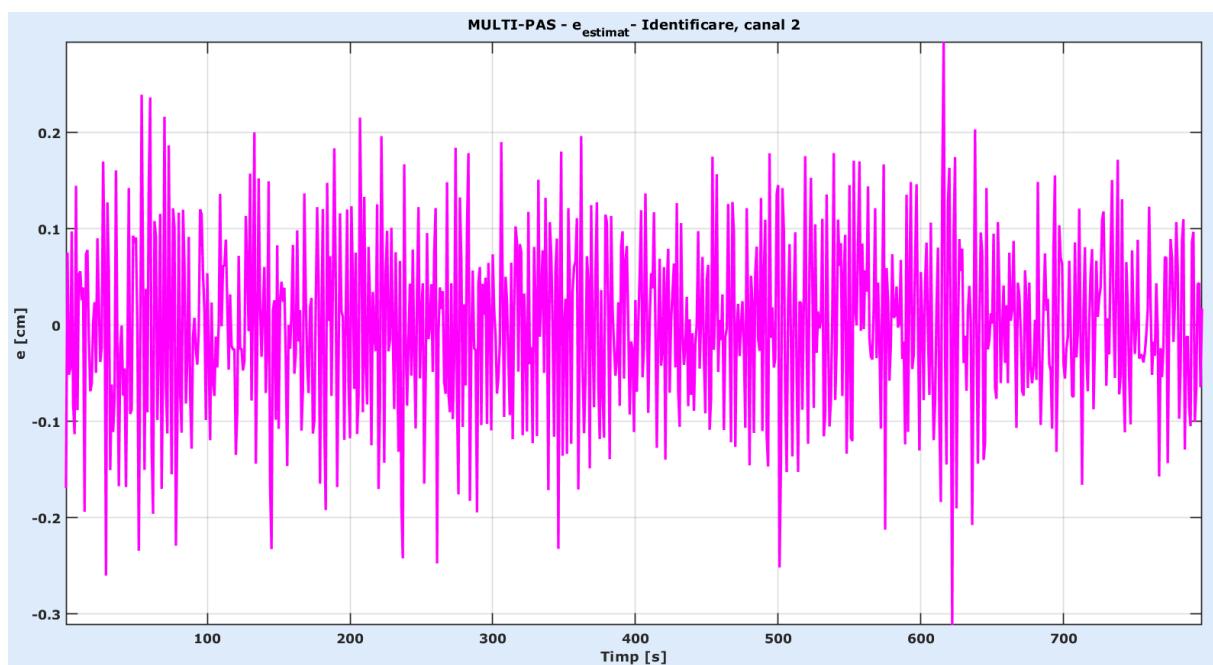


Fig. 6.28. Zgomotul alb estimat în cadrul procedurii numerice aferente MCMMP-MP, pe canalul 2 de ieșire, orizontul de identificare (scenariul MULTI-PAS)

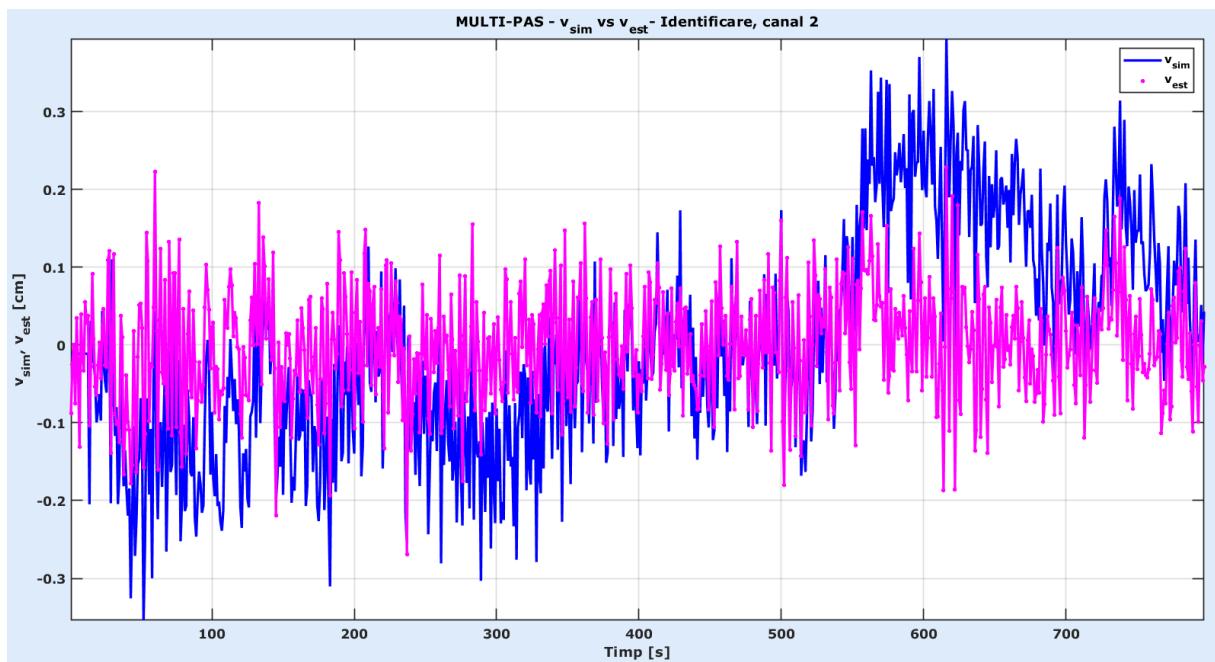


Fig. 6.29. Zgomotul colorat simulat versus estimat pe canalul 2 de ieșire, orizontul de identificare (scenariul MULTI-PAS)

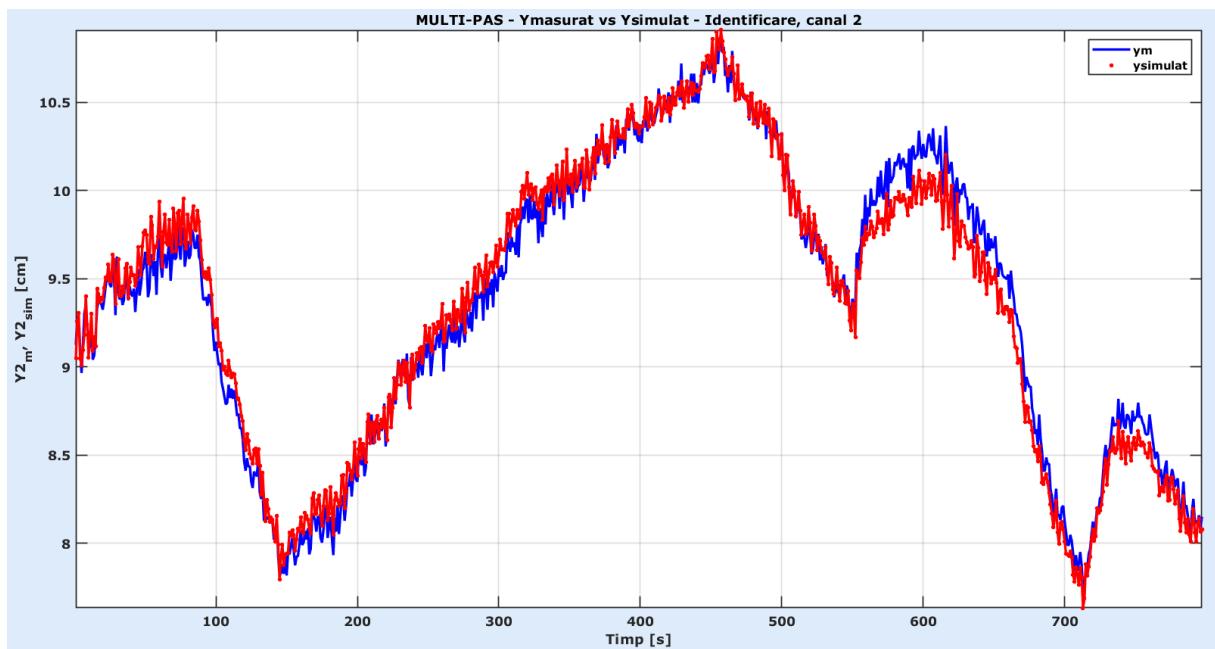


Fig. 6.30. Semnalul de ieșire măsurat versus integral simutat pe canalul 2 de ieșire, orizontul de identificare (scenariul MULTI-PAS)

Identificare neliniară pe bază de modele NARMAX

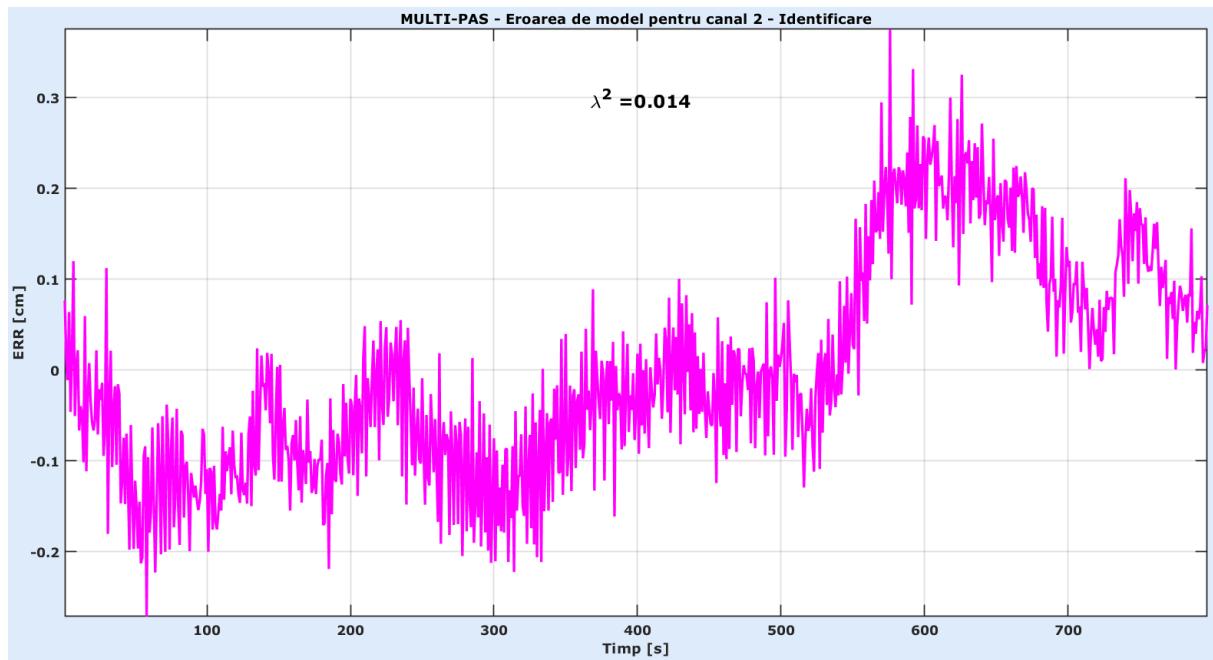


Fig. 6.31. Eroarea de model pe canalul 2 de ieșire, orizontul de identificare (scenariul MULTI-PAS)

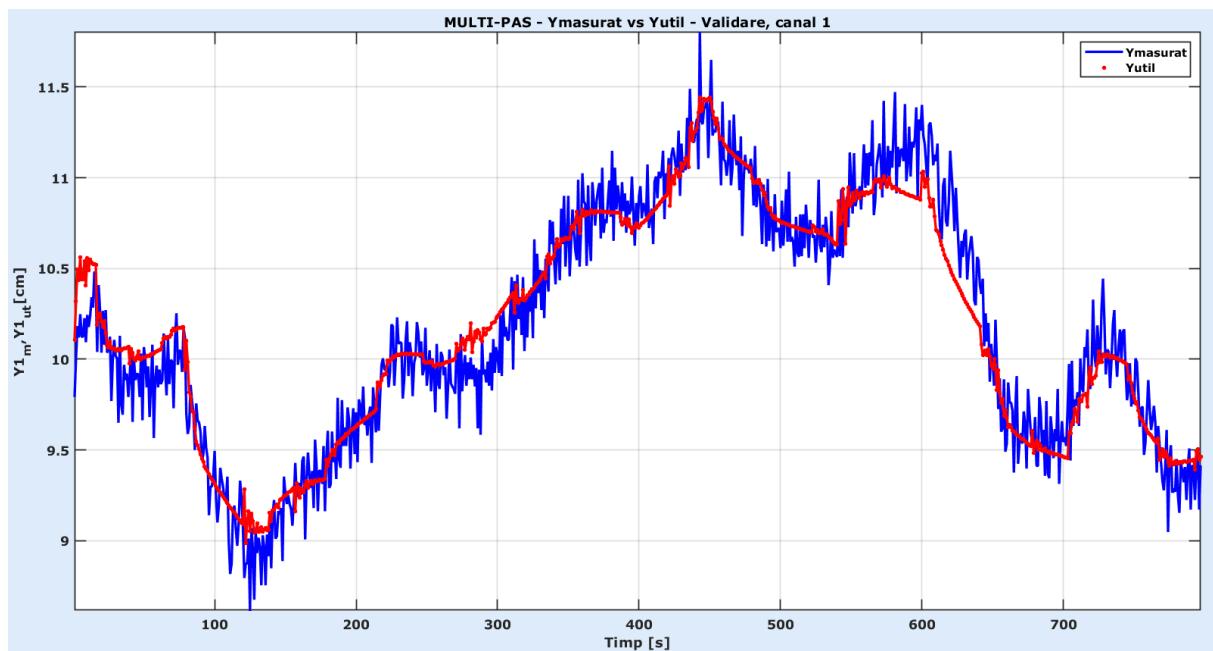


Fig. 6.32. Semnalul de ieșire măsurat versus util simulat pe canalul 1 de ieșire, orizontul de validare (scenariul MULTI-PAS)

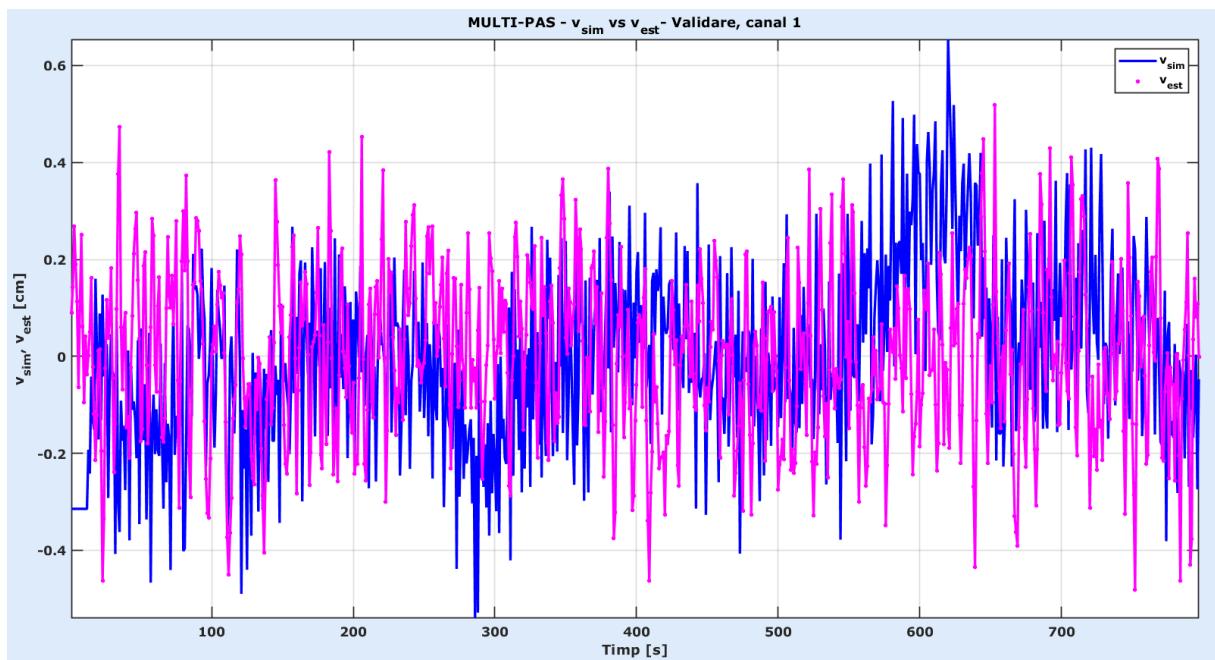


Fig. 6.33. Zgomotul colorat simulat versus estimat pe canalul 1 de ieșire, orizontul de validare (scenariul MULTI-PAS)

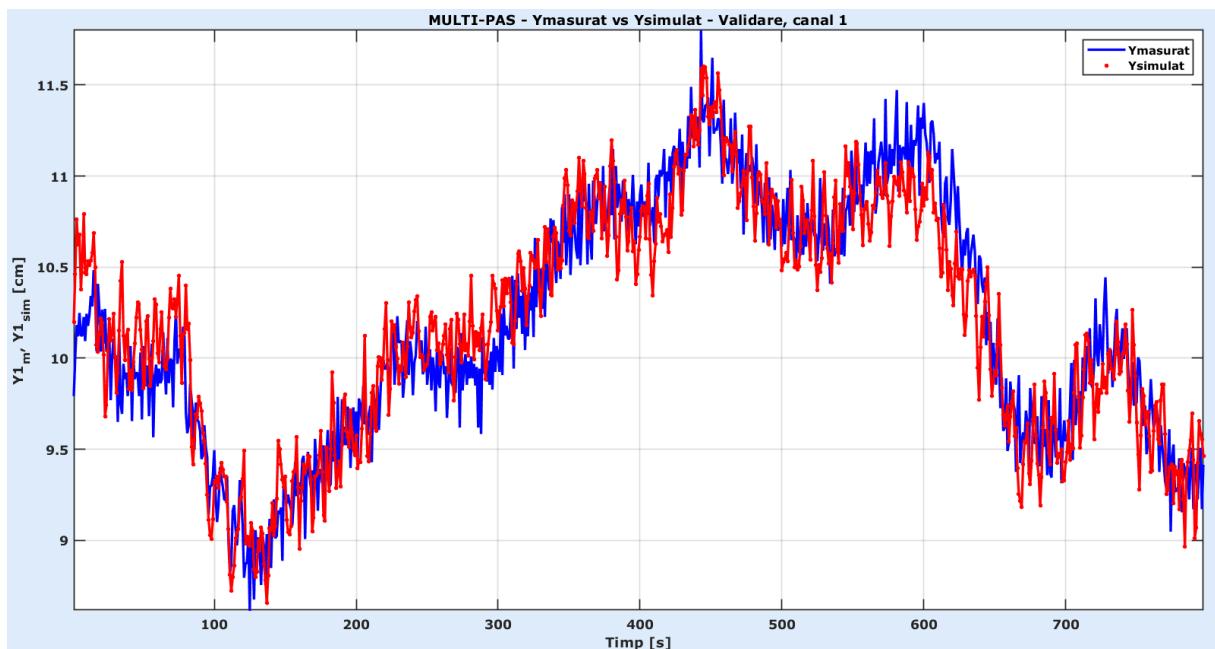


Fig. 6.34. Semnalul de ieșire măsurat versus integral simulat pe canalul 1 de ieșire, orizontul de validare (scenariul MULTI-PAS)

Identificare neliniară pe bază de modele NARMAX

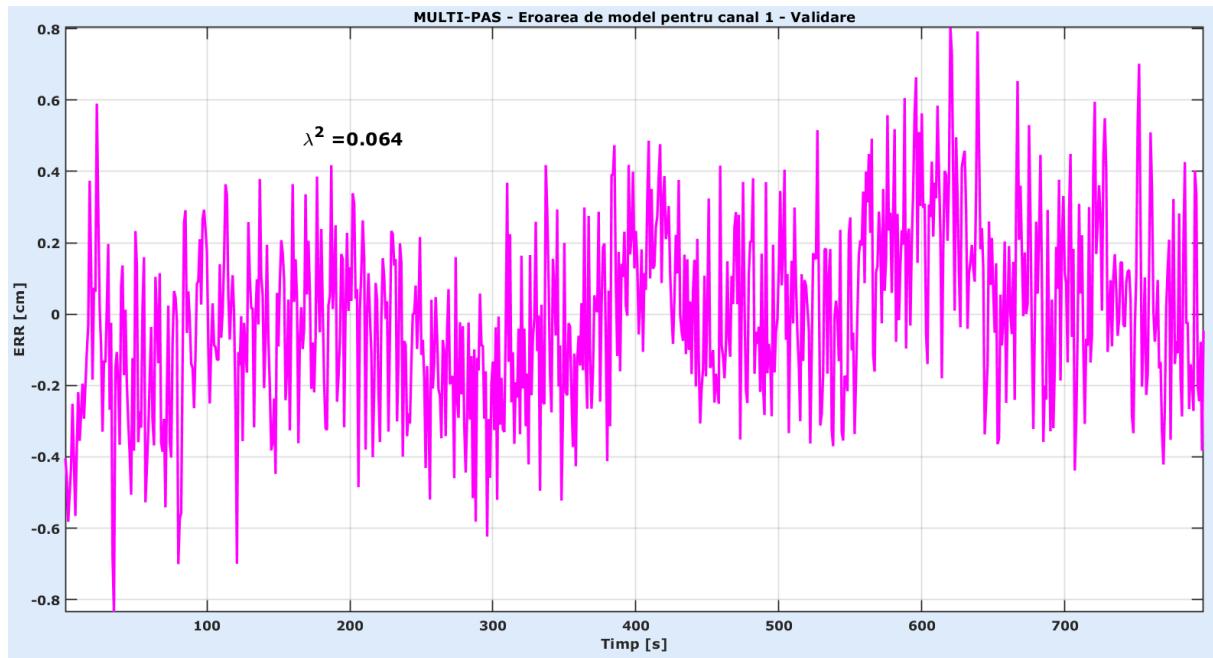


Fig. 6.35. Eroarea de model pe canalul 1 de ieșire, orizontul de validare (scenariul MULTI-PAS)

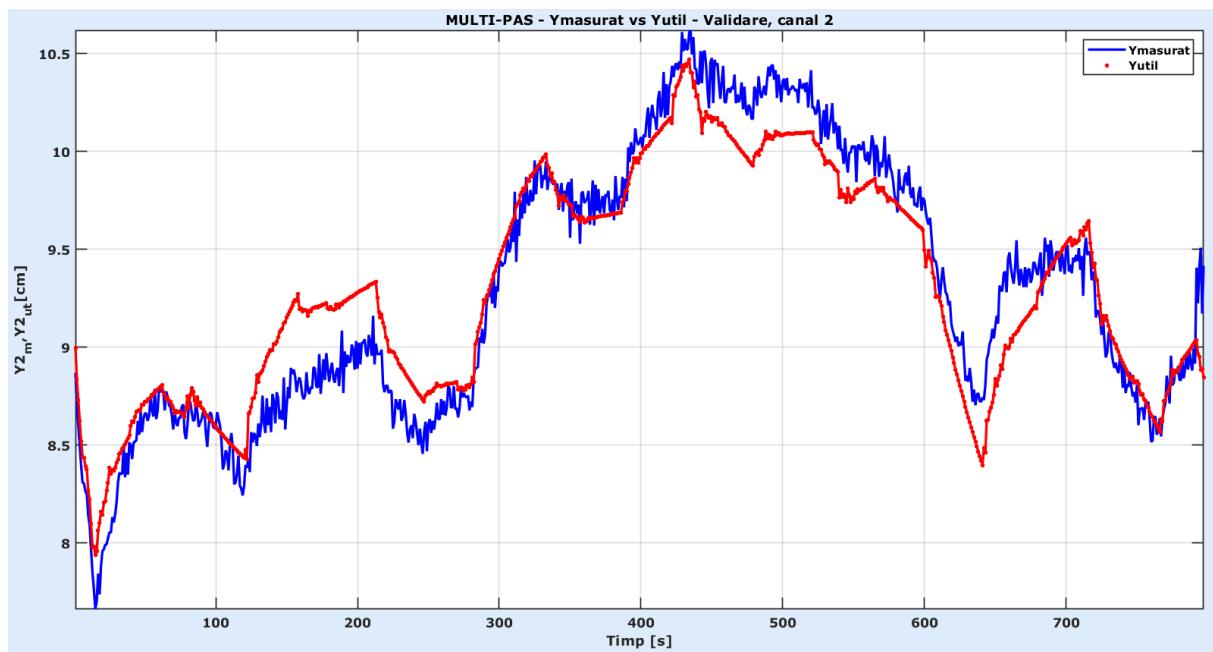


Fig. 6.36. Semnalul de ieșire măsurat versus util simulat pe canalul 2 de ieșire, orizontul de validare (scenariul MULTI-PAS)

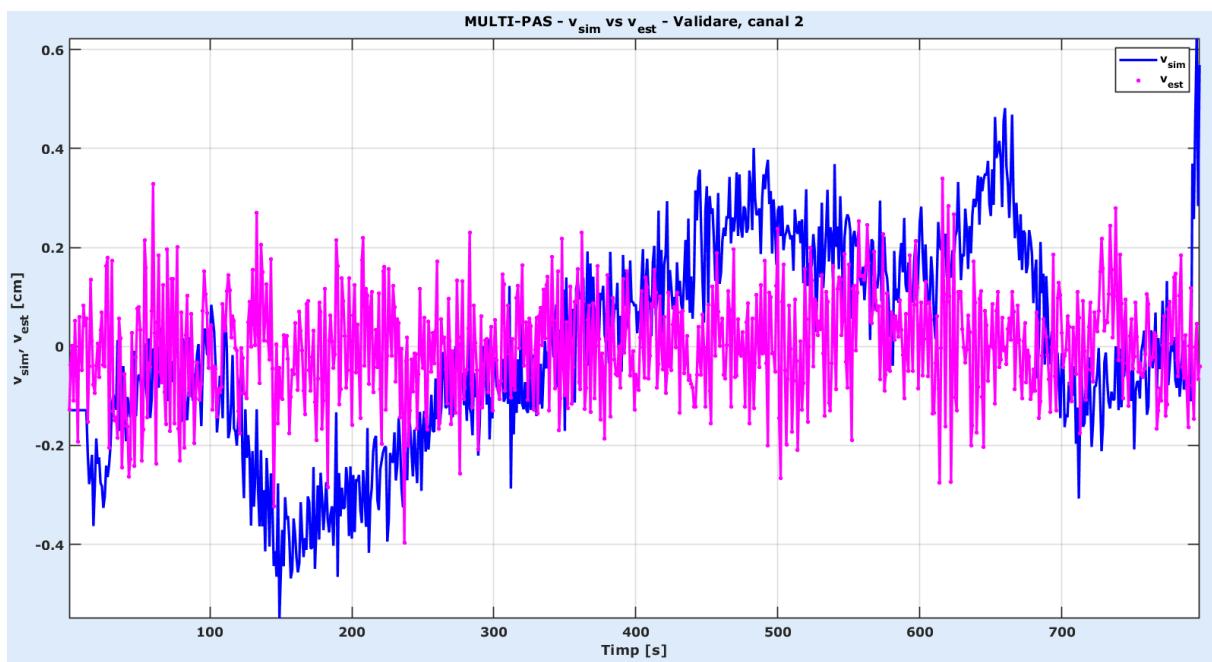


Fig. 6.37. Zgomotul colorat simulat versus estimat pe canalul 2 de ieșire, orizontul de validare (scenariul MULTI-PAS)

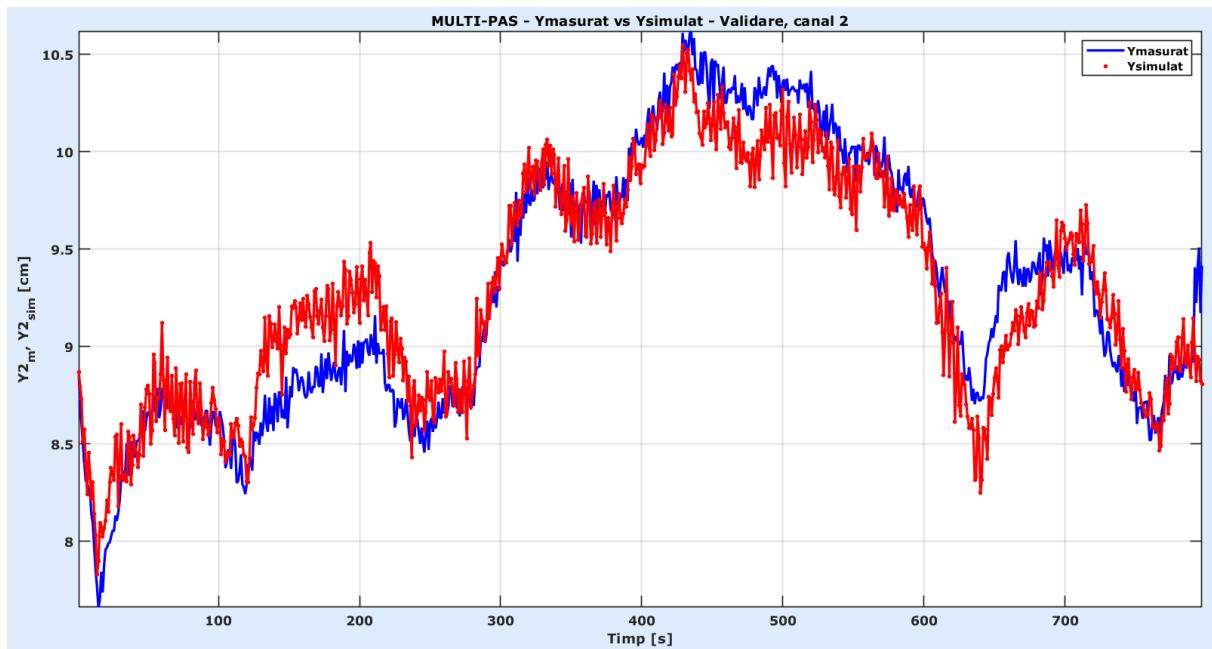


Fig. 6.38. Semnalul de ieșire măsurat versus integral simulat pe canalul 2 de ieșire, orizontul de validare (scenariul MULTI-PAS)

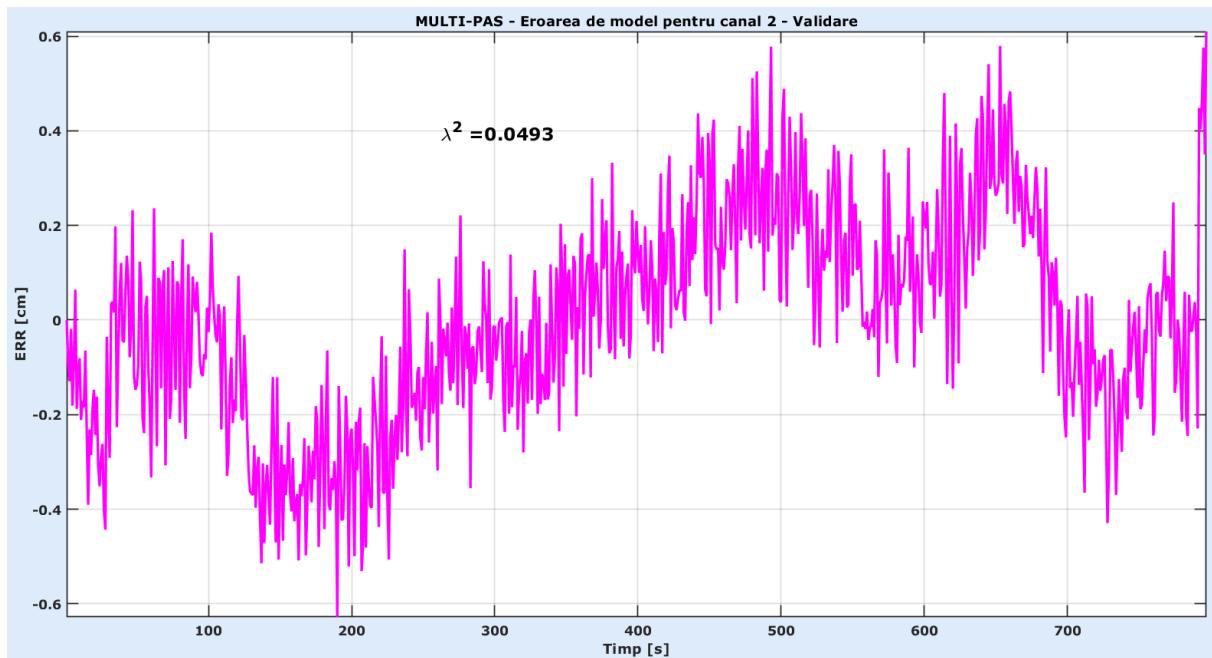


Fig. 6.39. Eroarea de model pe canalul 2 de ieșire, orizontul de validare (scenariul MULTI-PAS)

Acesta (NARMAX multi-pas) este modelul propice pentru utilizarea în controlul automat. Singura sa deficiență majoră o constituie faptul că, în cadrul acestor simulări, s-au folosit cele două estimații ale zgromotului alb oferite de MCMMMP. În cazul controlului automat, aceste estimații nu mai sunt disponibile. Totuși, există posibilitatea de a genera separat câte o instanță de zgromot alb Gaussian, de medie nulă, pe fiecare canal în parte, având dispersia egală cu zgromotului alb estimat de către MCMMMP-MP, eventual modulată de factorul de amplitudine aferent din ecuațiile (5.19). În această manieră, modelul de identificare NARMAX multi-pas poate fi integrat cu ușurință într-o schemă de control automat.

7. Concluzii și dezvoltări posibile ulterioare

Obiectivul principal al lucrării, acela de a analiza performanța unui model NARMAX identificat pentru o instalație neliniară precum ASTANK2, a fost atins. Cu ajutorul unei metode de identificare potrivite (MCMMMP-MP cu implementarea numeric stabilă MCMMMP-OR) și a unei metaeuristici (din clasa AG), am determinat modele care nu numai că sunt valide, ci care au și un procentaj de potrivire destul de bun. Mai mult, am efectuat o analiză comparativă între două tipuri de modele – unul care se bazează pe predicția uni-pas și altul care folosește predicția multi-pas, pentru a determina care dintre ele ar fi recomandat de utilizat într-o aplicație de control automat.

Elaborarea unei astfel de lucrări a necesitat un tip îndelungat de documentare și înțelegere a tuturor principiilor teoretice care urmau a fi puse în practică, având în vedere că Identificarea Neliniară a Sistemelor nu face obiectul de studii al pregătirii de licență. De asemenea, pentru obținerea celor mai bune modele a fost esențială etapa de testare, cea mai mare provocare constând în selectarea corespunzătoare a parametrilor AG și obținerea zgromotelor colorate, separat de ieșirile utile ale modelului NARMAX.

În viitor, se pot aplica și alte metaeuristici pentru determinarea optimală a indicilor structurali, în vederea efectuării unor eventuale comparații cu rezultatele prezentate în

Absolvent: Andreea-Cristina Voinea

această lucrare. Mai mult decât atât, se poate avansa în direcția proiectării unei legi de control pentru instalația hidraulică, care să asigure rejecția perturbațiilor și menținerea nivelelor coloanelor de lichid din rezervoare în jurul unor valori de referință.

Întreaga activitate de cercetare a urmărit să ofere, dincolo de obținerea unor rezultate concrete, șansa ca un viitor inginer de sistem să-și îmbunătățească și fixeze anumite cunoștințe din domeniu.

Listă contribuțiiilor personale

Identificare neliniară pe bază de modele NARMAX		
Student: Andreea-Cristina Voinea		
Coordonator: Prof.univ.dr.ing. Dan Ștefănoiu		
Nr. crt.	Activitate	Durată [zile]
1.	Cunoașterea caracteristicilor instalației ASTANK2	1
2.	Alegerea unei proceduri de identificare experimentală în urma întâlnirilor cu profesorul coordonator pentru stabilirea planului de lucru	4
3.	Documentarea privind modelele NARMAX	3
4.	Implementarea rutinelor pentru construcția Metodei Celor Mai Mici Pătrate Multi-Pas	11
5.	Implementarea rutinelor pentru determinarea optimală a indicilor structurali cu ajutorul metaeuristicii Algoritmilor Genetici	15
6.	Implementarea rutinelor pentru simularea modelului	10
7.	Testarea modelelor obținute	9
8.	Analiza soluțiilor rezultate	2
9.	Erori identificate și remedierea lor	7
10.	Redactarea lucrării de diplomă	15
	Total	77

Notă: Durata este exprimată în zile echivalente de lucru, 1 zi = 8 ore.

Bibliografie

- [CUL2015] Culită J., Ștefănoiu D., Dumitrașcu A. - *ASTANK2: Analytical Modeling and Simulation*, The 20-th International Conference on Control Systems and Computer Science, CSCS-20 (ISBN 978-1-4799-1780-8), Bucharest, România, pp. 141-148 (Vol. 1), May 27–29, 2015.
- [CUL2017] Culită J., Ștefănoiu D. - *Multi-Model Identification of Pumping System in ASTANK2 Plant*, The 21-th International Conference on Control Systems and Computer Science, CSCS-21 (ISBN 978-1-5386-1839-4), Bucharest, Romania, pp. 59–66, May 29–31, 2017.
- [LUT2014] Lută C.C. - *Algoritmi Genetici*, Vol.I, (ISBN: 978-973-0-16089-5), Slatina, 2014.
- [MAT2022] MathWorks Help Center. URL: <https://ch.mathworks.com> (ultima accesare: 20.06.2022).
- [MIT1995] Mitchell M. - *An Introduction to Genetic Algorithms*, The MIT Press, Cambridge, Massachusetts, U.S.A., 1995.
- [POP2021] Popescu D. - Strategii Avansate de Comunicații - Note de curs, 2021. URL: <https://curs.upb.ro/2021/course/view.php?id=5702> (ultima accesare: 25.06.2022).
- [SOA2006] Soare C., Iliescu S.St., Tudor V., Făgărășan I., Dragomir O., Dragomir F. - *Proiectarea Asistată de Calculator în Matlab și Simulink*, Editura AGIR (ISBN: 978-973-720-092-1), București, 2006.
- [SOD1989] Söderström T., Stoica P. - *System Identification*, Prentice Hall, London, U.K., 1989.
- [ȘTE2005] Ștefănoiu D., Culită J., Stoica P. - *Fundamentele Modelării și Identificării Sistemelor*, Editura Printech (ISBN: 973-718-368-1), București, România, Decembrie 2005.
- [ȘTE2013] Ștefănoiu D., Culită J., Tudor F.S. - *Abordări Experimentale de Identificare a Proceselor și Fenomenelor*, Editura AGIR (ISBN: 978-973-720-435-6), București, România, Ianuarie 2013.
- [ȘTE2014] Ștefănoiu D., Borne P., Popescu D., Filip F.Gh., El Kamel A. - *Optimization in Engineering Sciences – Metaheuristics, Stochastic Methods and Decision Support*, John Wiley & Sons & ISTE Press (ISBN: 978-1-84821-498-9), London, U.K., December 2014.
- [ȘTE2020] Ștefănoiu D., Culită J. - *Joint Stochastic Spline and Autoregressive Identification Aiming Order Reduction Based on Noisy Sensor Data*, Sensors Journal, Vol. 20, No. 18, article #5038, September 2020.

Identificare neliniară pe bază de modele NARMAX

[STE2021a] Ștefănoiu D. - *Identificarea Sistemelor* - Note de curs, 2021. URL: <https://curs.upb.ro/2021/course/view.php?id=5683> (ultima accesare: 25.06.2022).

[STE2021b] Ștefănoiu D., Culită J. - *Optimal Identification and Metaheuristic PID Control of a Two-Tank System*, Electronics Journal, Special Issue on “Control of Nonlinear Systems and Industrial Processes”, ISSN 2079-9292, EISSN 2079-9292, Vol. 10, No. 9, article #1101, May 2021.